

Estudo de caso para diagnóstico de fitopatogenias em hortaliças

Victor Hugo Ciurlini

Universidade de Brasília

Brasília, Brasil

Email: victorciurlini@gmail.com

Bruno Carvalho Faria dos Santos

Universidade de Brasília

Brasília, Brasil

Email: brunofga1@gmail.com

Abstract—The wide possibilities of technological applications using a single-board computer as Raspberry Pi, cannot be limited by the classroom, in this work we approach the integration of computer vision in a microprocessed system using leaf diseases as the case study.

I. INTRODUÇÃO

O uso de tecnologia para lidar com problemas das mais variadas áreas é uma tendência derivada da alta integração e conectividade da era digital, de aplicações para indústria 4.0, laboratórios científicos, à aplicações no dia-a-dia da população, a automatização em qualquer grau pode trazer benefícios em termos de acréscimo de produção, aumento de lucros, melhoria na qualidade de vida, além de garantir maior segurança nas operações.

A busca por automatizar o processo de reconhecimento de padrões em imagens é uma tarefa que vem sendo desenvolvida desde o fim da década de 50 quando surgiram os primeiros paradigmas da Inteligência Artificial (IA), desde então o nível de capacidade, complexidade e aplicação de reconhecimento de padrões tem avançado muito graças à dedicação de acadêmicos e entusiastas no desenvolvimento de técnicas de Aprendizagem de Máquina e Visão Computacional.

O setor do agronegócio tem investido no uso das chamadas tecnologias de precisão, a embarcação de sistemas eletrônicos vêm ocorrendo desde o maquinário usado em grandes lavouras, até nas etapas de processamento e escoamento de produção, e controle de qualidade das plantações.

II. JUSTIFICATIVA

De acordo com um estudo do CEPEA (Centro de Estudos Avançados em Economia Aplicada) em conjunto com a CNA (Confederação da Agricultura e Pecuária do Brasil), da soma de bens e serviços dos segmentos do agronegócio, que representaram em 2019 o valor de R\$1,55 Trilhão (24% do PIB brasileiro de 2019), o setor agrícola respondeu à 68% deste valor, [1] e de janeiro à novembro de 2020 em relação ao mesmo período de 2019, teve um aumento de 18,16% [2] logo, é o ramo que representa o principal vetor econômico do PIB do agronegócio brasileiro.

Patógenos representam a maior parcela de perdas econômicas na agricultura, cerca de 50 bilhões de euros (315 bilhões de reais) anualmente, o que equivale à 64% (494

bilhões de reais) do valor de exportações do agronegócio brasileiro em 2020 [3]

Conhecer os vetores de disseminação das doenças é uma tarefa primordial para que sejam tomadas medidas de controle como eliminação do patógeno, rotação de culturas, de forma que ocorra manejo das plantas já infectadas a fim de reduzir os danos, de modo a tornar a produção economicamente viável e sustentável, uma vez que moléstias patogênicas podem ocasionar um fator limitante no desenvolvimento das plantas. [3]

III. REFERENCIAL TEÓRICO

A. Doenças em plantas

Doenças fúngicas e viroses que afetam as folhas das plantas, podem comprometer a área foliar, a estética e o potencial de mercado, apresentam características de infecção distintas como deformidade, mudança de coloração, pústulas com esporos, associadas aos vetores, logo, à partir da identificação dos sintomas de infecção da folha é possível determinar que tipo de patógeno atuou sobre aquela planta e consequentemente, será possível traçar o planejamento de mitigação, controle e erradicação do problema.

1) *Ferrugem*: A ferrugem-foliar é uma doença causada pela fungo *Puccinia triticina*, ocasionando queda de folhas e em estado mais avançado até infectando os caules das plantas, é caracterizado pelo aparecimento esporos, que parecem um "pó", com tonalidade amarelo-escura, , como pode ser evidenciado pelas figuras 1.

2) *Cercosporiose*: Cercosporiose é uma doença causada pelo fungo *Cercospora sp*, também conhecida como olho de pombo, possui como características lesões necróticas de coloração pardo-acinzentada, de formato irregular, com centro esbranquiçado, como pode ser evidenciado pelas figuras 2,3.

3) *Míldio*: O Míldio é uma doença causada pelo fungo *Bremia lactucae*, possui como características manchas verde-claras ou amarelas, de tamanho variável, como pode ser evidenciado pela figura 4.

4) *Oídio*: O Oídio é uma doença causada pelo fungos (*Erysiphe cichoracearum*, possui como características a formação de manchas esbranquiçadas na parte superficial da folha, chegando à coloração cinza-escuro quando a doença avança para a folha toda, como pode ser evidenciado pela figura 5.



Fig. 1. Identificação de Cercosporiose em uma folha de Café (*Coffea*). Fonte: DOENÇAS DO CAFÉ



Fig. 4. Identificação de míldio em uma folha de Alface (*Lactuca sativa* L.), é possível notar a coloração esbranquiçada na superfície. Fonte: DOENÇAS ALFACE



Fig. 2. Identificação de Cercosporiose em uma folha de Pimenta-de-cheiro (*Capsicum chinense*). Fonte: DOENÇAS EM HORTALIÇAS



Fig. 5. Identificação de Oídio em uma folha, é possível notar a coloração esbranquiçada na superfície. Fonte: DOENÇAS EM HORTALIÇAS



Fig. 3. Identificação de Cercosporiose em uma folha de Caruru (*Talinum triangulare*). Fonte: DOENÇAS EM HORTALIÇAS



Fig. 6. Identificação da flor-preta na folha de Morango (*Fragaria x ananassa*), é possível notar a mancha circular com coloração escura. Fonte: MORANGUEIRO

5) **Antracnose:** A antracnose, ou flor-preta, é causada pelo fungo *Colletotrichum acutatum*, possui como características a necrose da haste da planta e outros órgãos florais, é a principal doença que acomete morangueiros, e nas folhas é identificado por uma mancha circular escura, como pode ser evidenciado pela figura 6.

B. Aprendizagem de Máquina

É um subcampo da Engenharia e da ciência da computação que evoluiu do estudo de reconhecimento de padrões e da teoria do aprendizado computacional em inteligência artificial. Esse subcampo explora a construção de algoritmos que podem

aprender com seus erros e fazer previsões sobre dados a partir de duas abordagens de aprendizagem: supervisionada, não supervisionada e por reforço. Isso permite produzir decisões e resultados confiáveis e repetíveis.

Tais algoritmos podem fazer previsões a partir de amostras ou tomar decisões guiadas unicamente por dados, sem qualquer tipo de programação. Embora semelhante, em certos aspectos, da estatística computacional, que faz previsões com o uso dos computadores, o aprendizado de máquina é usado em tarefas computacionais onde criação e programação de

algoritmos explícitos é impraticável.

C. Visão Computacional

A visão computacional é o processo de modelagem e replicação da visão humana usando software e hardware. A visão computacional é uma disciplina que estuda como reconstruir, interromper e compreender uma cena 3d a partir de suas imagens 2d em termos das propriedades da estrutura presente na cena.

Visão computacional e reconhecimento de imagem são termos frequentemente usados como sinônimos, mas o primeiro abrange mais do que apenas analisar imagens. Isso porque, mesmo para os seres humanos, “ver” também envolve a percepção em muitas outras frentes, juntamente com uma série de análises. Cada ser humano usa cerca de dois terços do seu cérebro para o processamento visual, por isso não é nenhuma surpresa que os computadores precisariam usar mais do que apenas o reconhecimento de imagem para obter sua visão de forma correta.

realizadas por sistemas como *Single-Board Computers* que são sistemas microprocessados Dependendo da complexidade do algoritmo a ser implementado, podem ser usados até supercomputadores.

A visão computacional é área que desenvolve técnicas utilizadas para “ensinar” um agrupamento de características para o sistema, de modo que esse sistema depois possa ser capaz de reconhecer essas características em um conjunto de informações, identificação e reconhecimento de objetos ou pessoas e determinação das características dos mesmos, são aplicações que podem ser

IV. RASPBERRY PI

É um computador de placa única de baixo custo, possui um processador ARM Cortex-A53 de 64-bits SoC de 1.4GHz com quatro núcleos de processamento, possui uma porta *ethernet* com conectividades:

- 2.4GHz e 5GHz IEEE 802.11.b *wireless LAN*

Memória,

- 1GB SDRAM

V. OBJETIVOS

Desenvolvimento de um sistema portátil de baixo custo de avaliação em tempo real de patógenos em folhas de monocultura usando visão computacional.

VI. ESCOPO

O projeto visa otimizar as plantações, identificando patógenos e gerando uma base de dados acessíveis para geração de indicadores de qualidade através da base de dados.




Fig. 7. Raspberry Pi 3B+ *Single-Board Computer* utilizado para implementação do sistema de diagnóstico. Fonte: DATASHEET

VII. MATERIAIS E MÉTODOS

Para esse projeto será usado uma Raspberry Pi 3B. Ela será responsável por hospedar o banco de dados, processar a imagem, realizar a identificação de patógenos através de um modelo de classificação e controlar acessos de dados. O fluxo se seguirá da seguinte forma:

- 1) O usuário tira uma foto da folha a ser estudada;
- 2) O usuário subirá a imagem ao Google drive;
- 3) A Raspberry acessará a imagem e armazenará localmente;
- 4) A Raspberry realizará um processamento da imagem;
- 5) O modelo usará a imagem processada para realizar a classificação;
- 6) A hora, a imagem e o resultado será armazenada em um banco de dados hospedado pela Raspberry;

A. Processamento de Imagem

As etapas e técnicas que serão seguidas para o treinamento e classificação das imagens são apresentadas na figura 8, e para a aplicação específica para as folhas, segue a lista a seguir:

- 1) Aquisição
- 2) Conversão da imagem RGB em formato HSV;
- 3) Normalizar pixel verde;
- 4) Remoção das máscaras;
- 5) Segmentação dos componentes;
- 6) Obtenção dos segmentos das características desejadas;
- 7) Método de co-ocorrência de cores;
- 8) Avaliação das estatísticas de textura.

B. OpenCV

O *Open Source Computer Vision Library* (OpenCV) é uma biblioteca multiplataforma de visão computacional de código aberto, contém mais de 2500 algoritmos otimizados, oferece

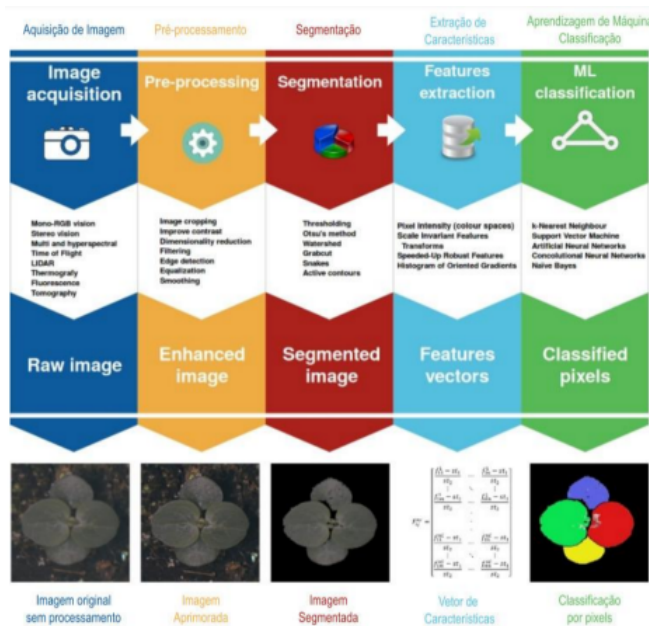


Fig. 8. Esquemático do fluxo de processamento da imagem. Fonte: FITODI-AGNOSE

Interface Gráfico do Usuário (GUI), Álgebra Linear, Estrutura de Dados que possibilitam a identificação de bordas, segmentação de imagem, reconhecimento de rostos e gestos, detecção de movimento. [4]

VIII. REQUISITOS

A. Requisitos funcionais

- RF001 - A Raspberry deve estar conectada a rede;
- RF002 - Receber uma imagem pela rede;
- RF003 - A Raspberry deverá realizar o tratamento da imagem para o modelo de identificação de patógenos;
- RF004 - A Raspberry deverá realizar a identificação de patógenos através da imagem tratada;
- RF005 - A Raspberry deverá armazenar a hora, a imagem e o resultado do modelo de identificação do patógeno em um banco MySQL;
- RF006 - O banco deverá liberar o acesso á usuários cadastrados;
- RF007 - O usuário deverá ter acesso aos dados registrados no banco de dados para análises futuras;

B. Requisitos não funcionais

- RNF001 - O usuário não deverá encontrar problemas em enviar a imagem para a raspberry;
- RNF002 - O sistema deve ser de fácil acesso e manutenção;

REFERENCES

- [1] CNA BRASIL. Agronegócio avança em novembro e resultado recorde vai se consolidando, 2020.
- [2] PIB DO AGRONEGÓCIO. Agronegócio avança em novembro e resultado recorde vai se consolidando, 2021.

- [3] embrapa. Importância, problemas e perspectivas do melhoramento visando resistência a viroses em plantas, 2020.
- [4] Fabio Souza, Rodrigo Nogueira, and Roberto Lotufo. Portuguese named entity recognition using bert-crf. 2020.