

Estudo de caso para diagnóstico de fitopatogenias em hortaliças

Victor Hugo Ciurlini
Universidade de Brasília
Brasília, Brasil
Email: victorciurlini@gmail.com

Bruno Carvalho Faria dos Santos
Universidade de Brasília
Brasília, Brasil
Email: brunofga1@gmail.com

Abstract—The wide possibilities of technological applications using a single-board computer as Raspberry Pi, cannot be limited by the classroom, in this work we approach the integration of computer vision in a microprocessed system using leaf diseases as the case study.

I. INTRODUÇÃO

O uso de tecnologia para lidar com problemas das mais variadas áreas é uma tendência derivada da alta integração e conectividade da era digital, de aplicações para indústria 4.0, laboratórios científicos, à aplicações no dia-a-dia da população, a automatização em qualquer grau pode trazer benefícios em termos de acréscimo de produção, aumento de lucros, melhoria na qualidade de vida, além de garantir maior segurança nas operações.

A busca por automatizar o processo de reconhecimento de padrões em imagens é uma tarefa que vem sendo desenvolvida desde o fim da década de 50 quando surgiram os primeiros paradigmas da Inteligência Artificial (IA), desde então o nível de capacidade, complexidade e aplicação de reconhecimento de padrões tem avançado muito graças à dedicação de acadêmicos e entusiastas no desenvolvimento de técnicas de Aprendizagem de Máquina e Visão Computacional.

O setor do agronegócio tem investido no uso das chamadas tecnologias de precisão, a embarcação de sistemas eletrônicos vêm ocorrendo desde o maquinário usado em grandes lavouras, até nas etapas de processamento e escoamento de produção, e controle de qualidade das plantações.

II. JUSTIFICATIVA

De acordo com um estudo do CEPEA (Centro de Estudos Avançados em Economia Aplicada) em conjunto com a CNA (Confederação da Agricultura e Pecuária do Brasil), da soma de bens e serviços dos segmentos do agronegócio, que representaram em 2019 o valor de R\$1,55 Trilhão (24% do PIB brasileiro de 2019), o setor agrícola respondeu à 68% deste valor, [1] e de janeiro à novembro de 2020 em relação ao mesmo período de 2019, teve um aumento de 18,16% [2] logo, é o ramo que representa o principal vetor econômico do PIB do agronegócio brasileiro.

Patógenos representam a maior parcela de perdas econômicas na agricultura, cerca de 50 bilhões de euros (315 bilhões de reais) anualmente, o que equivale à 64% (494

bilhões de reais) do valor de exportações do agronegócio brasileiro em 2020 [3]

Conhecer os vetores de disseminação das doenças é uma tarefa primordial para que sejam tomadas medidas de controle como eliminação do patógeno, rotação de culturas, de forma que ocorra manejo das plantas já infectadas a fim de reduzir os danos, de modo a tornar a produção economicamente viável e sustentável, uma vez que moléstias patogênicas podem ocasionar um fator limitante no desenvolvimento das plantas. [3]

III. REFERENCIAL TEÓRICO

A. Doenças em plantas

Doenças fúngicas e viroses que afetam as folhas das plantas, podem comprometer a área foliar, a estética e o potencial de mercado, apresentam características de infecção distintas como deformidade, mudança de coloração, pústulas com esporos, associadas aos vetores, logo, à partir da identificação dos sintomas de infecção da folha é possível determinar que tipo de patógeno atuou sobre aquela planta e consequentemente, será possível traçar o planejamento de mitigação, controle e erradicação do problema.

1) *Ferrugem*: A ferrugem-foliar é uma doença causada pela fungo *Puccinia triticina*, ocasionando queda de folhas e em estado mais avançado até infectando os caules das plantas, é caracterizado pelo aparecimento esporos, que parecem um "pó", com tonalidade amarelo-escura, , como pode ser evidenciado pelas figuras 1.

2) *Cercosporiose*: Cercosporiose é uma doença causada pelo fungo *Cercospora sp*, também conhecida como olho de pomba, possui como características lesões necróticas de coloração pardo-acinzentada, de formato irregular, com centro esbranquiçado, como pode ser evidenciado pelas figuras 2,3.

3) *Míldio*: O Míldio é uma doença causada pelo fungo *Bremia lactucae*, possui como características manchas verde-claras ou amarelas, de tamanho variável, como pode ser evidenciado pela figura 4.

4) *Oídio*: O Oídio é uma doença causada pelo fungos (*Erysiphe cichoracearum*, possui como características a formação de manchas esbranquiçadas na parte superficial da folha, chegando à coloração cinza-escuro quando a doença avança para a folha toda, como pode ser evidenciado pela figura 5.



Fig. 1. Identificação de Cercosporiose em uma folha de Café (*Coffea*). Fonte: DOENÇAS DO CAFÉ



Fig. 4. Identificação de míldio em uma folha de Alface (*Lactuca sativa* L.), é possível notar a coloração esbranquiçada na superfície. Fonte: DOENÇAS ALFACE



Fig. 2. Identificação de Cercosporiose em uma folha de Pimenta-de-cheiro (*Capsicum chinense*). Fonte: DOENÇAS EM HORTALIÇAS



Fig. 5. Identificação de Oídio em uma folha, é possível notar a coloração esbranquiçada na superfície. Fonte: DOENÇAS EM HORTALIÇAS



Fig. 3. Identificação de Cercosporiose em uma folha de Cariru (*Talinum triangulare*). Fonte: DOENÇAS EM HORTALIÇAS



Fig. 6. Identificação da flor-preta na folha de Morango (*Fragaria x ananassa*), é possível notar a mancha circular com coloração escura. Fonte: MORANGUEIRO

5) **Antracnose:** A antracnose, ou flor-preta, é causada pelo fungo *Colletotrichum acutatum*, possui como características a necrose da haste da planta e outros órgãos florais, é a principal doença que acomete morangueiros, e nas folhas é identificado por uma mancha circular escura, como pode ser evidenciado pela figura 6.

B. Aprendizagem de Máquina

É um subcampo da Engenharia e da ciência da computação que evoluiu do estudo de reconhecimento de padrões e da teoria do aprendizado computacional em inteligência artificial. Esse subcampo explora a construção de algoritmos que podem

aprender com seus erros e fazer previsões sobre dados a partir de duas abordagens de aprendizagem: supervisionada, não supervisionada e por reforço. Isso permite produzir decisões e resultados confiáveis e repetíveis.

Tais algoritmos podem fazer previsões a partir de amostras ou tomar decisões guiadas unicamente por dados, sem qualquer tipo de programação. Embora semelhante, em certos aspectos, da estatística computacional, que faz previsões com o uso dos computadores, o aprendizado de máquina é usado em tarefas computacionais onde criação e programação de

algoritmos explícitos é impraticável.

C. Visão Computacional

A visão computacional é o processo de modelagem e replicação da visão humana usando software e hardware. A visão computacional é uma disciplina que estuda como reconstruir, interromper e compreender uma cena 3d a partir de suas imagens 2d em termos das propriedades da estrutura presente na cena.

Visão computacional e reconhecimento de imagem são termos frequentemente usados como sinônimos, mas o primeiro abrange mais do que apenas analisar imagens. Isso porque, mesmo para os seres humanos, “ver” também envolve a percepção em muitas outras frentes, juntamente com uma série de análises. Cada ser humano usa cerca de dois terços do seu cérebro para o processamento visual, por isso não é nenhuma surpresa que os computadores precisariam usar mais do que apenas o reconhecimento de imagem para obter sua visão de forma correta.

realizadas por sistemas como *Single-Board Computers* que são sistemas microprocessados Dependendo da complexidade do algoritmo a ser implementado, podem ser usados até supercomputadores.

A visão computacional é área que desenvolve técnicas utilizadas para “ensinar” um agrupamento de características para o sistema, de modo que esse sistema depois possa ser capaz de reconhecer essas características em um conjunto de informações, identificação e reconhecimento de objetos ou pessoas e determinação das características dos mesmos, são aplicações que podem ser

IV. RASPBERRY PI

É um computador de placa única de baixo custo, possui um processador ARM Cortex-A53 de 64-bits SoC de 1.4GHz com quatro núcleos de processamento, possui uma porta *ethernet* com conectividades:

- 2.4GHz e 5GHz IEEE 802.11.b *wireless LAN*

Memória,

- 1GB SDRAM

V. OBJETIVOS

Desenvolvimento de um sistema portátil de baixo custo de avaliação em tempo real de patógenos em folhas de monocultura usando visão computacional.

VI. ESCOPO

O projeto visa otimizar as plantações, identificando patógenos e gerando uma base de dados acessíveis para geração de indicadores de qualidade através da base de dados.



Fig. 7. Raspberry Pi 3B+ *Single-Board Computer* utilizado para implementação do sistema de diagnóstico. Fonte: DATASHEET

VII. MATERIAIS E MÉTODOS

Para esse projeto será usado uma Raspberry Pi 3B. Ela será responsável por hospedar o banco de dados, processar a imagem, realizar a identificação de patógenos através de um modelo de classificação e controlar acessos de dados. O fluxo se seguirá da seguinte forma:

- 1) O usuário tira uma foto da folha a ser estudada;
- 2) O usuário subirá a imagem ao Google drive;
- 3) A Raspberry acessará a imagem e armazenará localmente;
- 4) A Raspberry realizará um processamento da imagem;
- 5) O modelo usará a imagem processada para realizar a classificação;
- 6) A hora, a imagem e o resultado será armazenada em um banco de dados hospedado pela Raspberry;

A. Processamento de Imagem

As etapas e técnicas que serão seguidas para o treinamento e classificação das imagens são apresentadas na figura 8, e para a aplicação específica para as folhas, segue a lista a seguir:

- 1) Aquisição
- 2) Conversão da imagem RGB em formato HSV;
- 3) Normalizar pixel verde;
- 4) Remoção das máscaras;
- 5) Segmentação dos componentes;
- 6) Obtenção dos segmentos das características desejadas;
- 7) Método de co-ocorrência de cores;
- 8) Avaliação das estatísticas de textura.

B. OpenCV

O *Open Source Computer Vision Library* (OpenCV) é uma biblioteca multiplataforma de visão computacional de código aberto, contém mais de 2500 algoritmos otimizados, oferece

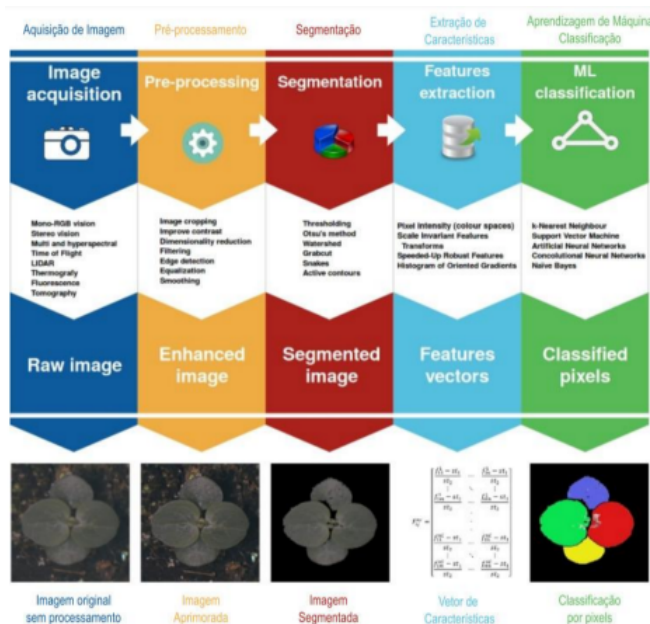


Fig. 8. Esquemático do fluxo de processamento da imagem. Fonte: FITODI-AGNOSE

Interface Gráfica do Usuário (GUI), Álgebra Linear, Estrutura de Dados que possibilitam a identificação de bordas, segmentação de imagem, reconhecimento de rostos e gestos, detecção de movimento. [4]

VIII. REQUISITOS

A. Requisitos funcionais

- RF001 - A Raspberry deve estar conectada a rede;
- RF002 - Receber uma imagem pela rede;
- RF003 - A Raspberry deverá realizar o tratamento da imagem para o modelo de identificação de patógenos;
- RF004 - A Raspberry deverá realizar a identificação de patógenos através da imagem tratada;
- RF005 - A Raspberry deverá armazenar a hora, a imagem e o resultado do modelo de identificação do patógeno em um banco MySQL;
- RF006 - O banco deverá liberar o acesso á usuários cadastrados;
- RF007 - O usuário deverá ter acesso aos dados registrados no banco de dados para análises futuras;

B. Requisitos não funcionais

- RNF001 - O usuário não deverá encontrar problemas em enviar a imagem para a raspberry;
- RNF002 - O sistema deve ser de fácil acesso e manutenção;

IX. DESENVOLVIMENTO

1) *Banco de dados:* O banco de dados a ser utilizado será o banco de dados estruturado e sequencial MYSQL. Essa escolha partiu da necessidade de ser possível acessar múltiplas

informações ligadas por uma chave primária de uma tabela. Esse banco de dados terá um usuário root para gerência do banco de dados e um usuário para consumo do banco de dados, devolvendo as informações armazenadas na tabela.

A comunicação será realizada em C através de sockets. O algoritmo irá consultar o repositório hospedado na nuvem através da aplicação owncloud sempre que o usuário subir uma imagem nova. caso não haja uma imagem nova, a aplicação consultará novamente em um intervalo de tempo pré determinado. Caso haja, a imagem passará por um pré-processamento para ser alimentada ao modelo de classificação. O modelo retornará uma resposta do tipo string que será armazenada no banco de dados, junto com a data em que a solução foi realizada e o endereço de armazenamento local da raspberry para a imagem para futuras aplicações.

A. Processamento de imagens para detecção de fitopatogenias em hortaliças

1) *Da aquisição das imagens:* A aquisição das imagens ocorreu por meio da base Digipathos, Base de Imagens de Doenças de Plantas (PDDb), mantida pela Embrapa Informática Agropecuária, e tem como função servir de referência para desensolvimento de métodos para detecção e reconhecimento automático de doenças em plantas.

Para a aplicação deste trabalho, a quantidade imagens obtida para cada classe foi:

- Antracnose: 6 imagens;
- Cercosporiose: 136 imagens;
- Ferrugem: 430 imagens;
- Míldio: 596 imagens;
- Oídio: 395 imagens.

2) Do pré-processamento das imagens por meio de Visão Computacional para o desenvolvimento do Classificador:

A primeira etapa foi o redimensionamento das imagens, a partir da análise do referencial teórico chegou-se ao valor de dimensão: 400x550 *pixels*, e a aplicação do algoritmo gerou o seguinte resultado:




Fig. 9. Comparação entre a Imagem Original (Figura 1) e a imagem redimensionada (Figura 2).

Após o redimensionamento, o próximo passo foi a filtragem dessas imagens para suavização, com objetivo de remover ruídos nas imagens, como à base de dados possui vários tipos de imagens que foi gerado por diferentes fitopatologistas, não há uma boa homogeneidade, devido à isso foi utilizado uma metodologia de uso de múltiplos filtros, foram eles Blur(7x7),

Mediano(7), Gaussiano((7x7),0) e Bilateral(9,75,75), apresentados nas imagens (10) e (11), todos implementados à partir de funções prontas da biblioteca OpenCV e dimensões determinadas pelos referenciais teóricos e empiricamente.




Fig. 10. Imagem após aplicação dos filtros Blur (Figura 1) e Mediana (Figura 2).




Fig. 11. Imagem após aplicação dos filtros Gauss (Figura 1) e Bilateral (Figura 2).

Dos referenciais teóricos também foi possível determinar que após a filtragem das imagens há modos variados de prosseguir o processamento, um sendo usando a imagem com a representação em RGB (*Red, Green and Blue*), mas na maioria foi feito a conversão da representação de cores de RGB para HSV (*Hue Saturation Value*) (12), com a justificativa de que os valores dos *pixels* no modo RGB estão correlacionados com a luminosidade que incide nas folhas na hora que a foto é tirada, ocasionando uma redução da acurácia da detecção, ao passo que a descrição dos *pixels* pelo modo HSV é baseado primariamente na percepção de cores humano, H é a componente que define a cor, S é a componente que determina a pureza da cor, e V regula o brilho.




Fig. 12. Comparação entre a Imagem na representação de cores RGB (Figura 1) e a imagem filtrada e na representação de cores HSV (Figura 2).

O próximo passo para segmentação da imagem em função da detecção das doenças, é a segmentação pela limiarização de cores, para isso é necessário indicar uma faixa de valores de *pixels* para extração da imagem, para isso uma máscara é configurada à partir da imagem representada pelo modo HSV e a faixa de valores dos *pixels* que quer-se extrair.




Fig. 13. Máscara para segmentação pela limiarização de cores.

Após o desenvolvimento da máscara, é aplicada na imagem original, de modo à deixar em evidência apenas a patologia (14), como as fitopatologias utilizadas neste trabalho também possuem muitas características geométricas, após a aplicação da máscara, também foi aplicado um detector de bordas *Canny*, implementado por meio da biblioteca do OpenCV




Fig. 14. Comparação entre a Imagem Original (Figura 1) e a imagem após a finalização do processo de aplicação da máscara (Figura 2).

O resultado final do pré-processamento da imagem original, após aplicação de algoritmos de redimensionamento, filtragem, segmentação e detecção de borda pode ser visto na imagem (15)

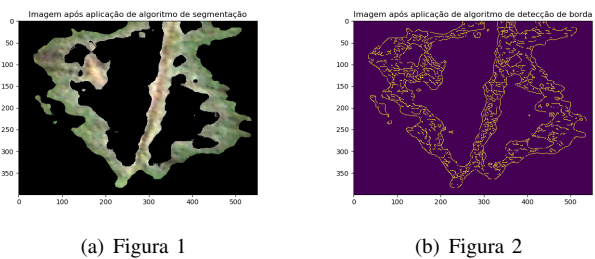


Fig. 15. Comparação entre a Imagem Original (Figura 1) e a imagem após a finalização do processo de aplicação da máscara (Figura 2).

REFERENCES

- [1] CNA BRASIL. Agronegócio avança em novembro e resultado recorde vai se consolidando, 2020.
- [2] PIB DO AGRONEGÓCIO. Agronegócio avança em novembro e resultado recorde vai se consolidando, 2021.
- [3] embrapa. Importância, problemas e perspectivas do melhoramento visando resistência a viroses em plantas, 2020.
- [4] Fabio Souza, Rodrigo Nogueira, and Roberto Lotufo. Portuguese named entity recognition using bert-crf. 2020.