

UNIVERSIDADE FEDERAL FLUMINENSE
JUAN PABLO ENRICI

FITO DIAGNOSE DIGITAL: DETECÇÃO DE DOENÇAS DE PLANTAS VIA
IMAGENS DIGITAIS

Niterói
2018

JUAN PABLO ENRICI

**FITO DIAGNOSE DIGITAL: DETECÇÃO DE DOENÇAS DE PLANTAS VIA
IMAGENS DIGITAIS**

Trabalho de Conclusão de Curso submetido ao
Curso de Tecnologia em Sistemas de Computa-
ção da Universidade Federal Fluminense como
requisito parcial para obtenção do título de Tecnó-
logo em Sistemas de Computação.

Orientador:

Bruno José Dembogurski

NITERÓI

2018

Ficha catalográfica automática - SDC/BEE

E56f Enrici, Juan Pablo
 Fito Diagnose Digital: Detecção de Doenças de Plantas via
 Imagens Digitais / Juan Pablo Enrici ; Bruno José
 Dembogurski, orientador. Niterói, 2018.
 74 f. : il.

 Trabalho de Conclusão de Curso (Graduação em Tecnologia
 de Sistemas de Computação)-Universidade Federal Fluminense,
 Escola de Engenharia, Niterói, 2018.

 1. Visão Computacional. 2. Aprendizado de máquina. 3.
 Agronomia. 4. Produção intelectual. I. Título II.
 Dembogurski, Bruno José, orientador. III. Universidade Federal
 Fluminense. Escola de Engenharia. Departamento de Ciência da
 Computação.

CDD -

JUAN PABLO ENRICI

**FITO DIAGNOSE DIGITAL: DETECÇÃO DE DOENÇAS DE PLANTAS VIA
IMAGENS DIGITAIS**

Trabalho de Conclusão de Curso submetido ao
Curso de Tecnologia em Sistemas de Computa-
ção da Universidade Federal Fluminense como
requisito parcial para obtenção do título de Tecnó-
logo em Sistemas de Computação.

Niterói, ____ de _____ de 2018.

Banca Examinadora:

Prof. Bruno José Dembogurski, D.Sc. – Orientador
UFRJ - Universidade Federal do Rio de Janeiro

Prof. Edelberto Franco Silva, D.Sc. – Avaliador
UFJF - Universidade Federal de Juiz de Fora

Dedico este trabalho a minha esposa e ao
meu estimado filho.

AGRADECIMENTOS

A Deus, que sempre iluminou a minha caminhada.

A meu Orientador Bruno José Dembogurski pelo estímulo e atenção que me concedeu durante o curso.

Aos Colegas de curso pelo incentivo e troca de experiências.

A todos os meus familiares e amigos pelo apoio e colaboração.

“Eu acredito que às vezes são as pessoas
que ninguém espera nada que fazem as
coisas que ninguém consegue imaginar.”
Alan Turing

RESUMO

A tecnologia da informação está presente em todas as áreas inclusive na agricultura. A rápida tomada de decisões, não somente previne problemas como tornam o setor cada vez mais competitivo e eficiente. Na computação, a visão computacional e a aprendizagem de máquina tem estado cada vez mais em destaque, sendo propósito de estudo e aplicação de muitos projetos destinados ao ambiente agrícola. Um exemplo é o importante serviço de consulta técnica de informações agronômicas através da observação de fotos digitais. Este trabalho visa mostrar os benefícios e possibilidades da utilização de análise de imagens para a detecção de doenças em plantas.

Palavras-chaves: Computação Gráfica, Agronomia, Visão Computacional, Processamento de Imagem, Aprendizagem de Máquina, Fito Diagnose Digital.

LISTA DE ILUSTRAÇÕES

Figura 1: Amostras de imagens utilizadas na detecção de doenças de plantas.....	18
Figura 2: Reconhecendo o local e o agente causador do dano.....	18
Figura 3: Detalhes de detecção e quantificação de área lesionada.....	19
Figura 4: Fluxo básico de processamento e análise de imagens.....	21
Figura 5: Interação planta, patógeno e meio ambiente.....	26
Figura 6: Representação da fisiologia e de sintomas de doenças em plantas.....	27
Figura 7: Etapas do processamento de imagens.....	30
Figura 8: Sistema de Visão Artificial (SVA) e suas principais etapas.....	30
Figura 9: Convenção das coordenadas x e y na imagem digital.....	32
Figura 10: Representação de imagem monocromática.....	33
Figura 11: Representação de imagem no padrão RGB.....	33
Figura 12: Intervalo do espectro eletromagnético.....	34
Figura 13: Modelo representativo do espaço de cores RGB.....	36
Figura 14: Modelo de representação do padrão HSV.....	37
Figura 15: Exemplo de limiarização de imagem.....	38
Figura 16: Exemplo de segmentação baseada em bordas.....	39
Figura 17: Exemplo de segmentação orientada por regiões.....	39
Figura 18: Exemplo de textura em imagens.....	41
Figura 19: Exemplo de extração de característica.....	41
Figura 20: Classificação de objetos em imagens.....	43
Figura 21: Separação linear de duas classes pela SVM.....	44
Figura 22: Diagrama de distribuição da Inteligência Artificial.....	45
Figura 23: Exemplo de processo de aprendizagem de máquina.....	46
Figura 24: Modelo não-linear de um neurônio.....	48
Figura 25: Rede Neural.....	48
Figura 26: Esquema de uma Rede Neural Convolucional.....	51
Figura 27: Fases de treino e aplicação da Aprendizagem de Máquina.....	52
Figura 28: Processo de detecção de doenças em plantas.....	53
Figura 29: Doenças Foliares.....	55

Figura 30: Aquisição de imagem de folha via foto digital.....	56
Figura 31: Pré-processamento de imagem de folhas.....	57
Figura 32: Exemplo de segmentação em folhas.....	58
Figura 33: Desafios da segmentação de imagem de folhas vegetais.....	59
Figura 34: Extração de característica usando FFT.....	60
Figura 35: Exemplo de detecção de contornos para extração de atributos.....	61
Figura 36: Detecção de padrões.....	62
Figura 37: Classificação de folhas normais das doentes.....	63
Figura 38: Reconhecimento de padrões para detecção e classificação.....	64
Figura 39: Diagrama ilustrativo de uma Rede Neural Convolucional.....	65
Figura 40: Visualização do treinamento de uma <i>Deep Learning</i>	66

LISTA DE ABREVIATURAS E SIGLAS

AgroTIC	- Tecnologia da Informação e Comunicação aplicado à agricultura
EMATER-MG	- Empresa de Assistência Técnica e Extensão Rural do Estado de Minas Gerais
EMBRAPA	- Empresa Brasileira de Pesquisa Agropecuária
EPAMIG	- Empresa de Pesquisa Agropecuária de Minas Gerais
MAPA	- Ministério da Agricultura, Pecuária e Abastecimento
FRUPEX	- Programa de Apoio à Produção e Exportação de Frutas, Hortaliças, Flores e Plantas Ornamentais
SOFTEX	- Associação para Promoção da Excelência do Software Brasileiro
PIB	- Produto Interno Bruto
IA	- Inteligência Artificial
ML	- Aprendizado de Máquina (<i>Machinhe Learning</i>)
DL	- Aprendizagem Profunda (<i>Deep Learning</i>)
RNA	- Rede Neural Artificial
PDI	- Processamento Digital de Imagem
SVA	- Sistema de Visão Artificial
HSV	- Matiz, Saturação e Valor (Hue Saturation Value)
RGB	- Vermelho, Verde e Azul (Red Green Blue)
FFT	- Transformada Rápida de Fourier (<i>Fast Fourier Transform</i>)
PCA	- Análise de Componentes Principais (<i>Principal Component Analysis</i>)
SIFT	- Transformação de Características Invariantes à Escala (<i>Scale Invariant Feature Transform</i>)
HAAR	- Tranformação de Características Gabor-Haar
HOG	- Histograma de Gradientes Orientados (<i>Histogram of Oriented Gradient</i>)

ORB	- Detector de características com base em pontos-chave (<i>Oriented Fast and Rotated BRIEF</i>)
SVM	- Máquina de Vetores de Suporte (<i>Support Vector Machine</i>)
MLP	- Perceptron Multicamadas (<i>Multilayer Perceptron</i>)
CNN	- Rede Neural Convolucional (<i>Convolutional Neural Network</i>)
DCNN	- Rede Neural Convulacional Profunda (<i>Deep Convulational Neural Network</i>)
IoT	- Internet das Coisas (<i>Internet of Things</i>)

SUMÁRIO

1 INTRODUÇÃO.....	15
1.1 Justificativa.....	16
1.2 Objetivo.....	16
1.3 Organização do trabalho.....	16
2 TRABALHOS RELACIONADOS.....	17
3 AGRICULTURA E TECNOLOGIA.....	22
3.1 Agricultura.....	22
3.2 Tecnologia no Campo.....	23
4 FUNDAMENTAÇÃO TEÓRICA.....	25
4.1 Doença de Plantas.....	25
4.1.1 Diagnose Vegetal.....	26
4.1.2 Fito Diagnose Digital.....	28
4.2 Processamento de Imagens.....	29
4.2.1 Imagem Digital.....	32
4.2.2 Sistema de Cores.....	34
4.2.2.1 Padrão de Cores RGB.....	35
4.2.2.2 Padrão de Cores HSV.....	36
4.2.3 Segmentação.....	37
4.2.3.1 Limiarização.....	38
4.2.3.2 Segmentação Baseada em Bordas.....	38
4.2.3.3 Segmentação Orientada a Regiões.....	39
4.2.4 Extração de Características.....	39
4.2.5 Classificação.....	42
4.3 Aprendizagem de Máquina.....	45
4.3.1 Reconhecimento de Padrões.....	47
4.3.2 Redes Neurais Artificiais.....	47
4.3.2.1 Rede Neural Convolucional.....	50
4.3.3 Reconhecimento e Interpretação.....	52
5 DETECÇÃO DE DOENÇAS DE PLANTAS.....	53

CONCLUSÕES E TRABALHOS FUTUROS.....	67
REFERÊNCIAS BIBLIOGRÁFICAS.....	68

1 INTRODUÇÃO

O uso mais intensivo das tecnologias da informação e comunicação no setor agrícola vem desde a década de 80, quando da introdução de microcomputadores no mercado a um preço mais acessível, utilizando planilhas eletrônicas e programas adaptados de administração e contabilidade (SOFTEX, 2016).

Em meados da década de 90 chega a *internet*, revolucionando a relação entre o homem e a informação. Posteriormente, a democratização do conhecimento se torna percebida com o desenvolvimento da telefonia móvel, através dos telefones inteligentes ou *smartphones*. Nos dias atuais, os mais diversos serviços e aplicativos estão disponíveis na palma da mão, a qualquer tempo e lugar.

Neste cenário de desenvolvimento, o agricultor pode se beneficiar através da troca rápida e acessível de conhecimento técnico, aumentando a produtividade e eficiência de suas tarefas, solucionando problemas e tomando decisões mais prontamente e segura possível. O homem do campo, antes afastado tecnologicamente, hoje está tão conectado e modernizado quanto nos centros urbanos.

A adoção dessas tecnologias pelo setor agrícola é ainda mais relevante quando se considera a emergência de pressões crescentes relacionadas a demanda por alimento, exigências ambientais, escassez de recursos naturais e problemas fitossanitários.

Dentre os diversos desafios no ambiente rural, uma das dificuldades do agricultor está relacionada ao acesso à assistência técnica para o controle de pragas e doenças, principalmente com respeito a diagnose e a adequada identificação do fitopatógeno.

Neste aspecto o avanço da tecnologia tem feito notáveis contribuições através do auxílio da visão computacional e da aprendizagem de máquina.

1.1 JUSTIFICATIVA

Em breve pesquisa literária relacionado a visão computacional e a plantas ficou evidente o enorme interesse que o assunto tem despertado impulsionados pela evolução tecnológica, pelos avanços da aprendizagem de máquina e pelas infinitas soluções que podem ser apresentadas ao agricultor.

1.2 OBJETIVO

Este trabalho visa o estudo dos benefícios da visão computacional na agricultura mostrando as possibilidades de uso na detecção de doenças em plantas, abordando aspectos técnicos importantes do processamento de imagens e da aprendizagem de máquina. Paralelamente, são apresentados alguns trabalhos que expõem propostas e experimentos em desenvolvimento, relacionados ao setor agrícola e as plantas.

1.3 ORGANIZAÇÃO DO TRABALHO

O capítulo dois relatará alguns trabalhos ligados à agricultura e a doenças de plantas em que o auxílio da computação se faz presente.

O capítulo três tratará sobre a agricultura e a tecnologia na atualidade.

No quarto capítulo serão conceituados os fundamentos teóricos sobre doença de plantas, processamento digital de imagem e aprendizagem de máquina, relevantes para o entendimento do tema. No último capítulo é apresentado de forma teórica um processo de detecção de doença de plantas por meio digital, apontando alguns desafios colocados pelos procedimentos computacionais.

Finalmente, nas conclusões serão apresentadas algumas observações adquiridas durante o estudo do tema.

2 TRABALHOS RELACIONADOS

Na literatura há vários trabalhos relacionados à agricultura onde se faz uso da visão computacional e da aprendizagem de máquina, a seguir são relatados os principais trabalhos que serviram de motivação para o estudo sobre a detecção de doenças de plantas por meio de imagens digitais.

No trabalho de Mohanty, Hughes e Salathé (2016), sob título “Usando Aprendizado Profundo para Detecção de Doenças Vegetais Baseadas em Imagem” (do inglês, “*Using Deep Learning for Image-Based Plant Disease Detection*”), é possível observar um experimento bastante interessante na detecção de doenças em folhas de plantas.

Neste trabalho os autores utilizaram redes neurais artificiais para fazer o reconhecimento de folhas doentes. Para tal, foi analisado um banco de imagens da PlantVillage, sendo este um sítio da internet especializado em coletar informações e fotos relacionados à agricultura.

Os autores, submeteram 38 classes de imagens ao redimensionamento, a segmentação, ao treinamento de aprendizagem e ao final executaram testes de detecção. Durante todo o processo os autores fizeram medições de performance e desempenho dos algoritmos utilizados.

Ao final deste experimento concluíram que embora as imagens sejam provenientes de ambientes controlados em que foram previamente selecionadas e usadas imagens de folhas soltas, a utilização das redes neurais tem seu trabalho facilitado pelo processamento de imagens e que no futuro a identificação poderá ser feita independente desta condição de entrada.

Concluíram também, que quanto maior for o banco de imagens utilizado maior será o conhecimento adquirido pelos algoritmos de aprendizagem. E que ao construírem dispositivos móveis cada vez mais avançados, todos poderão usufruir deste aprendizado disponibilizando respostas de detecção de doenças em tempo real e no próprio campo de cultivo.

Na Figura 1, são ilustradas as amostras de imagens das três versões diferentes do conjunto de dados da PlantVillage usadas em várias configurações experimentais no desenvolvimento e implementação dos testes. Nesta, as folhas (a) e (d) estão no formato colorido original, as (b) e (e) em tons de cinza e finalmente as folhas (c) e (f) estão no formato segmentado.




Figura 1: Amostras de imagens utilizadas na detecção de doenças de plantas. MOHANTY, SALATHÉ, 2016.

No trabalho de Fuentes (2017), sob o tema “Um Detector Robusto Baseado em Aprendizagem Profunda para o Reconhecimento de Doenças e Pragas em Tempo Real de Tomateiros” (do inglês, “*A Robust Deep-Learning-Based Detector for Real-Time Tomato Plant Diseases and Pests Recognition*”), a sua equipe elabora um sistema de detecção onde as imagens são obtidas *in loco*, em condições de campo.

Estes também, utilizam as redes neurais artificiais para alimentar a base de conhecimento. Mas, diferentemente do trabalho anterior, neste caso existe uma definição da espécie de planta, o tomateiro (Figura 2).




Figura 2: Reconhecendo o local e o agente causador do dano. Adaptada de FUENTES, 2017.

O fato do estudo focar em apenas uma espécie vegetal torna o procedimento mais eficiente, porém mais restritivo ao uso pelo agricultor comum. De qualquer modo, como o aprendizado de máquina foi realizado em um cenário real com folhas contendo diversas pragas e doenças do tomateiro, torna a experiência mais relevante. Neste trabalho a utilização de diversos extratores de características ou descritores fez do processamento de imagens igualmente importante ao aprendizado de máquina.

Nazaré Júnior (2009), em seu trabalho de “Detecção Automática da Área Foliar Danificada da Soja através de Imagens Digitais”, demonstra a importância do processamento de imagens para detecção de danos causados ao limbo foliar da soja e o quanto este procedimento pode acelerar a determinação de medidas de controle. Nele, é proposto um método para detecção e quantificação automática da área lesionada.

Este trabalho expõe fundamentos como pré-processamento, uso de padrões de cores, segmentação, filtragem de contornos e reconstrução morfológica.

Na Figura 3, pode ser observado a sequência da reconstrução do limbo foliar, tendo em (a) a imagem original, em (b) a imagem segmentada e em (c) a imagem reconstruída. Segundo o autor, através da subtração da imagem reconstruída (c) pela segmentada (b) se obtém a imagem dos danos e paralelamente a sua quantificação.




Figura 3: Detalhes de detecção e quantificação de área lesionada. NAZARÉ JÚNIOR , 2009.

O trabalho de Galvão (2018) sobre “Visão Computacional para Detecção de Doenças Fúngicas na Agricultura”, exemplifica o fato de que ao se desenvolver uma aplicação que se beneficie das técnicas de reconhecimento de padrões e aprendizado de máquina é necessário uma grande quantidade de imagens, de disponibilidade de tempo e da escolha adequada de ferramentas computacionais.

O estudo foi realizado sob uma espécie específica, o cafeeiro, focando um número reduzido de doenças. Neste experimento, foi exposto a dificuldade das técnicas quando utilizadas em folhas que estão em estágios de desenvolvimento avançados, como amarelecidas ou secas, ou quando as plantas estão em ambiente de campo.

Ghosal (2018) demonstra em seu trabalho "*An explainable deep machine vision framework for plant stress phenotyping*" (em português, "Um *framework* de visualização usando aprendizagem de máquina profunda para identificar sintomas de estresse em plantas."), que a visualização de sintomas para identificação de doenças de plantas pode ser demorada, tediosa e exigir profissionais tecnicamente qualificados.

Neste trabalho, os autores propõem um sistema de identificação automatizada não somente para facilitar o trabalho, como também evitar erros de diagnose e diminuir o desperdício de tempo e de recursos. O experimento faz o uso de redes neurais profundas para identificar o tipo de estresse foliar, para classificar o nível de estresse (baixo, médio ou alto) e para a quantificar a gravidade do dano causado por ação de agentes bióticos (micro-organismos) e abióticos (deficiências nutricionais, por exemplo). Segundo os autores o modelo aprendido pretende ser robusto o suficiente para atender um maior número de espécies vegetais.

WÄLDCHEN (2018), destaca o importante papel que a aprendizagem de máquina exerce ao auxiliar a identificação de espécies vegetais. Em seu trabalho intitulado "*Automated plant species identification -Trends and future directions*" (em português, "Identificação automatizada de espécies de plantas - Tendências e direções a seguir no futuro."), o autor faz uma abordagem ampla do processo desde a aquisição da imagem, passando por alguns detalhes do processamento de imagens, explicitando alguns descritores e ao final aborda em detalhes os aspectos e os desafios do aprendizado de máquina direcionado a identificar imagens de vegetais.

Sun (2017), no trabalho "*Deep Learning for Plant Identification in Natural Environment*" (em português, "Aprendizado Profundo para Identificação de Plantas em Meio Natural"), faz uso da aprendizagem de máquina para a identificação das plantas, assim como o trabalho de Wäldchen, exalta a importância da computação para a botânica e para a natureza de forma geral. Aponta inclusive que o avanço da tecnologia principalmente com a popularização dos *smartphones* favorecerá muito os estudos sobre ecologia. Os autores utilizaram a aprendizagem profunda para classificação de plantas em larga escala em ambiente natural. E mostram que os

modelos de classificação tradicionais dependem muito do pré-processamento para eliminar o fundo complexo e aprimorar os recursos desejados.

Finalmente, Perez-Sanz (2017), em seu trabalho "*Plant phenomics: an overview of image acquisition technologies and image data analysis algorithms*" (em português, "Fenômenos de plantas: uma visão geral das tecnologias de aquisição de imagens e algoritmos de análise de dados de imagem."), trata da importância da fenotipagem de plantas, dos processos de aquisição e análises de imagens e dos principais sistemas desenvolvidos para esta finalidade.

Na Figura 4, é ilustrado o fluxo básico de desenvolvimento de estudo de fenotipagem de plantas baseado em visão computacional, proposto por Perez-Sanz. Este esquema como poderá ser visto mais adiante, pode servir de exemplo para um esquema de detecção de doenças em plantas através de imagens digitais.

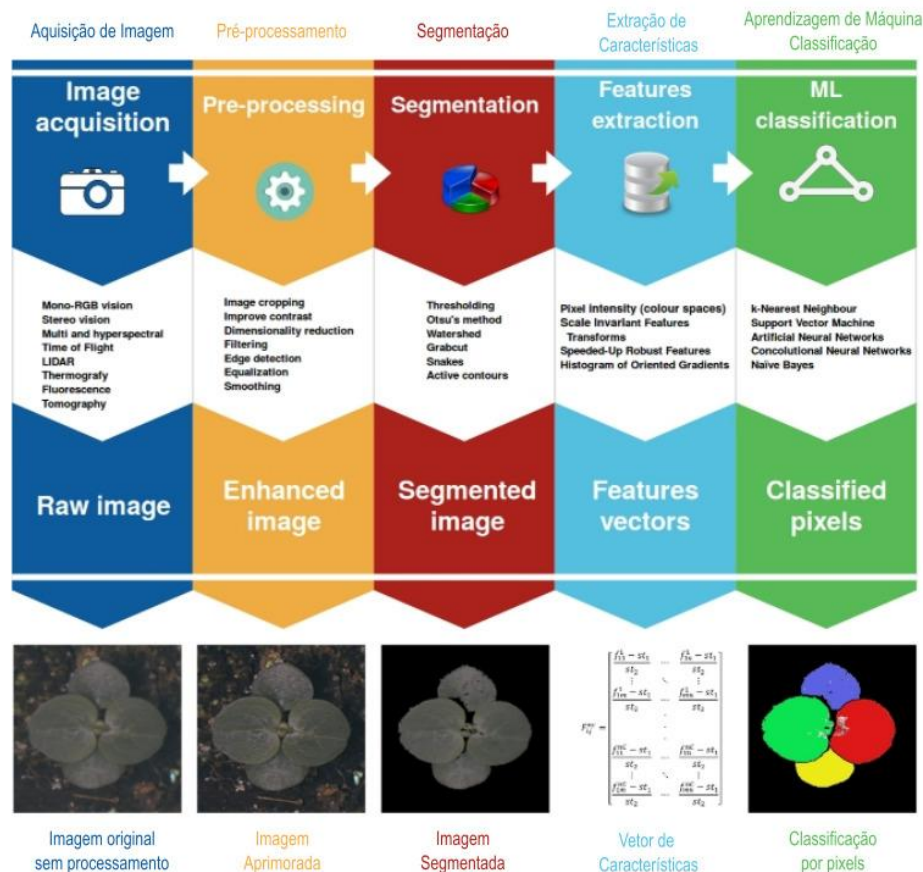


Figura 4: Fluxo básico de processamento e análise de imagens. Adaptado de PEREZ-SANZ, 2017.

3 AGRICULTURA E TECNOLOGIA

3.1 AGRICULTURA

A agricultura é por definição, “a arte de cultivar a terra e de plantar; arvicultura”, é o “conjunto de práticas que visam preparar o solo para a produção de vegetais e a criação de animais úteis e necessários ao homem.” (MICHAELIS, 2018).

A agricultura faz parte do setor primário da economia sendo fornecedor de alimento e de matéria-prima.

Independente do grau de desenvolvimento, do tamanho territorial de um país ou região, a agricultura é a principal responsável pela subsistência do ser humano.

Lopes (2013), salienta que na atualidade a agricultura é componente dos sistemas de agronegócios e de agroindústrias. Estes por sua vez, englobam todas as atividades de produção, processamento, distribuição e comercialização dos produtos provenientes da agricultura e da pecuária.

De acordo com o Ministério da Agricultura, Pecuária e Abastecimento do Brasil (MAPA), o agronegócio foi responsável por 24% do Produto Interno Bruto (PIB) de 2017, firmando sua relevante importância para a sociedade.

Segundo Petersen, Weid e Fernandes (apud BOSERUP, 1987), a história da agricultura pode ser interpretada como a busca incessante de novas práticas para a intensificação do uso do solo em resposta às crescentes demandas alimentares decorrentes dos aumentos demográficos. Ou seja, o campo está em constante revolução e desenvolvimento técnico.

Nas últimas décadas, a agricultura passou a fazer uso de práticas com propostas mais conservacionistas, por pressão de agentes de controle ambiental preocupados com as mudanças climáticas e preservação de áreas naturais, por pressão de escassez de recursos como fertilidade do solo e água e pela redução da área territorial liberada para o cultivo.

3.2 TECNOLOGIA NO CAMPO

O setor agrícola vem sendo obrigado a buscar o equilíbrio entre uma economia global mais sustentável e os grandes desafios da atualidade como as bruscas mudanças climáticas, a substituição de insumos de origem fóssil, as muitas restrições de água e fertilidade do solo, a segurança alimentar, a limitação territorial destinado à agricultura e o aumento da demanda por alimento e matéria-prima (MASSRUHÁ, LEITE e MOURA, 2014).

A tecnologia nesse cenário é parte imprescindível e estratégica para o desenvolvimento de toda a cadeia produtiva da agricultura.

Neste momento, as mais variadas inovações estão sendo incorporadas no cotidiano do homem do campo, seja na pequena agricultura familiar, seja nos grandes e complexos agronegócios.

Sistemas de administração rural, sistemas de monitoramento de variáveis meteorológicas, irrigação inteligente, agricultura de precisão, tratores autônomos, sensoriamento remoto, sistemas de informações geográficas são alguns destes exemplos de inovação.

As tecnologias da informação e da comunicação quando direcionadas ao desenvolvimento de soluções para o segmento agrário, formam as AgroTIC.

As AgroTIC tem atuação nas diversas atividades do setor, tanto em nível operacional como estratégico, sendo utilizadas desde as pequenas operações e procedimentos rotineiros até a gestão de agronegócios (MASSRUHÁ, LEITE, EVANGELISTA, SOUZA, 2014).

Do mesmo modo, que terminologias como agronegócio e agroindústria foram criadas e aceitas pela sociedade, a AgroTIC será em pouco tempo incorporada, tornando-se referência para a produção agrícola.

Massruhá, Leite e Moura (apud TING el al., 2011), faz a observação de que o desenvolvimento de tecnologias para o campo estão sujeitos aos grandes desafios impostos pela peculiaridade do setor como: a heterogeneidade inerente ao ecossistema de produção agrícola, os eventos extremos da atmosfera, a grande dispersão geoespacial, os requisitos da segurança alimentar, variabilidade e diversidade das culturas.

Por outro lado, a SOFTEX (2016) sinaliza que mesmo tendo grandes desafios, as perspectivas e prognósticos para a expansão e progresso das AgroTIC serão enormes.

Diversas oportunidades de negócios no setor agrícola serão abertas principalmente com o advento de novas tecnologias como da Internet das Coisas (IoT), da computação em nuvem e do *big data*, sendo cada vez mais difícil separar o mundo físico do digital.

Neste contexto, a visão computacional e a análise de imagens tem função valiosa ao transformar os dados coletados no campo em informações úteis ao agricultor.

Além dos exemplos observados no Capítulo 2, o processamento digital de imagens e aprendizagem de máquina estão presentes na detecção da floração em culturas, na classificação automatizada de sementes, no controle de qualidade na colheita e pós-colheita de frutos, na detecção e eliminação de ervas daninhas via sistemas inteligentes instalados em tratores de pulverização.

No próximo capítulo será abordado o conceito agrônômico sobre doença de plantas e posteriormente nos tópicos relacionados a computação serão expostos os conceitos de processamento de imagens digitais e de aprendizagem de máquina focando sempre nos detalhes que serão relevantes para o processo de detecção de doenças de plantas por imagens digitais.

4 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo serão abordados alguns tópicos de fundamentação teórica com intuito de fornecer informações úteis para o melhor entendimento do tema.

4.1 DOENÇA DE PLANTAS

As pragas estão presentes na agricultura desde a domesticação das plantas e dos animais, sendo um desafio constante tanto para pequeno quanto para o grande agricultor (BARBEDO; MEIRA, 2014).

As pragas são fatores limitantes para qualquer cultivo agrícola, segundo definição do MAPA, o termo “praga” aplica-se a qualquer espécie vegetal, animal ou micro-organismo que esteja presente em uma área e que cause danos a uma cultura ou ao seu produto: insetos, fungos, bactérias, nematoides, vírus e plantas invasoras. Ou seja, corresponde a todo organismo que se prolifera de forma desordenada ou fora de seu ambiente natural, causando danos a cultura, ao meio ambiente, às pessoas ou à economia.

Doença de planta é qualquer anormalidade causada por organismos vivos ou não, de maneira contínua, alterando seu metabolismo, resultando em queda de produção, queda na qualidade do produto, podendo expressar os sintomas durante o desenvolvimento até após a colheita, inviabilizando seu consumo ou comercialização (LOPES; AVILA, 2005).

As doenças de plantas são um dos principais limitantes de produção e subsistência alimentar nas regiões mais humildes e subdesenvolvidas.

Potencializadas no passado através do uso de monoculturas, de práticas não conservacionistas e ao exaurir os recursos naturais, as pragas e doenças afetam não somente as plantas de função alimentar como também, as ornamentais e as florestais.

As doenças não são consequência de uma alteração isolada, é resultado da interação entre uma planta suscetível, um agente patogênico e o meio ambiente. Nesta relação, pode ser incluído também, a ação do homem e do tempo, como ilustrado na relação da Figura 5. O homem através da interferência no manejo da cultura pode reduzir, paralisar ou até aumentar danos. E o tempo interferindo tanto pelo período em que o evento ocorre, quanto pela época ou estação climática do ano (ZAMBOLIM; LOPES; PICANÇO; COSTA, 2007).

De acordo com Júnior, Venzon, Teixeira e Pallini (2009), a agricultura moderna deve seguir ou fazer uso racional de um conjunto de tecnologias, objetivando o equilíbrio entre a produtividade, a preservação do meio ambiente e o bem-estar da sociedade.

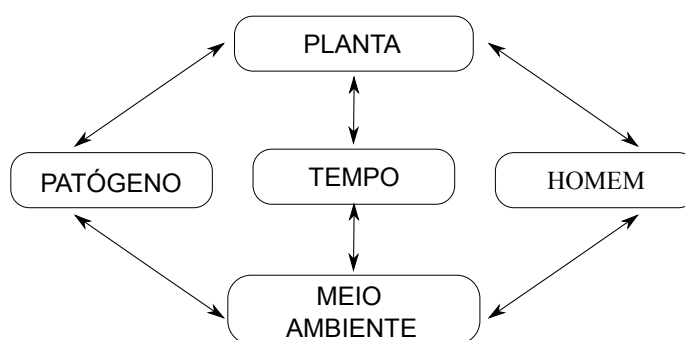


Figura 5: Interação planta, patógeno e meio ambiente.

4.1.1 Diagnose Vegetal

O sucesso do tratamento de uma doença depende principalmente da rapidez e eficiência de seu diagnóstico. A diagnose de doenças de plantas pode ser complexa e ampla, necessitando de diversas informações para serem conclusivas e ser possível indicar uma direção para a tomada de decisão dos tratos culturais (FRUPEX, 1995).

A diagnose é iniciada com a observação na planta da distribuição e tipo de sintomas. Posteriormente se faz a análise e identificação do agente causador.

No diagnóstico fitossanitário, são considerados fatores como: o estado geral da planta, o estágio de desenvolvimento vegetativo, a estrutura da planta onde

estão ocorrendo os danos ou sintomas, o manejo e os tratos culturais empregados, observações do microclima local, entre outros (CAROLLO; FILHO, 2016).

A Figura 6, demonstra as peculiaridades da identificação de algumas doenças e de certa maneira expõem a complexidade do processo de diagnóstico quando efetuado no campo. A ilustração mostra no lado esquerdo como seria o funcionamento fisiológico de uma planta saudável e no lado direito indica algumas manifestações ou sintomas.




Figura 6: Representação da fisiologia e de sintomas de doenças em plantas. Adaptado de AGRIOS, 2005.

4.1.2 Fito Diagnose Digital

Detectado algo de errado na área cultivada ou em alguma planta, é necessário a imediata descoberta do agente causador do problema, o que pode ser feito através da consulta a um técnico agrícola, engenheiro agrônomo ou laboratório especializado (REIS; RESENDE; SOUZA; ALMEIDA, 2009).

A tecnologia pode ter um papel importante nesta ação, pois muitas vezes o auxílio de um profissional não está prontamente disponível. Com o maior acesso à *internet*, com a chegada dos dispositivos móveis e o aumento da rede de telefonia celular, os serviços de consulta se tornaram acessíveis e importantes ao agricultor.

Esforços vêm sendo despendidos na criação de ferramentas computacionais que auxiliem no combate aos problemas fitossanitários. O objetivo dessas ferramentas é reduzir o tempo necessário para que as primeiras ações sejam postas em prática, especialmente na ausência de um especialista (BARBEDO; MEIRA, 2014).

A visão computacional e a análise de imagens são hoje um dos principais componentes em qualquer plataforma moderna. Técnicas baseadas em imagens são capazes de coletar grandes volumes de dados através de metodologias que não são invasivas e que não são destrutivas (SANTOS; YASSITEPE, 2014).

Evidentemente, a diagnose fitossanitária digital seria um primeiro passo ou alternativa. Pois, o diagnóstico fitossanitário é parte inicial para a profilaxia de um possível tratamento ou manejo agrícola. Outros fatores devem ser considerados como: a espécie vegetal, o estado geral da planta, a nutrição vegetal, a fertilidade do solo, a umidade do ar, a umidade do solo, o microclima, o estágio desenvolvimento e as análises laboratoriais (CAROLLO; FILHO, 2016).

Segundo Barbedo e Meira (2014), dentre os métodos de detecção de doenças em plantas que podem ser destacados na literatura são os propostos por Sena Junior et al. (2003) e por Story et al. (2010). O primeiro tem como base a segmentação da imagem por limiarização e na contagem dos objetos detectados, enquanto o segundo realiza uma análise de regressão duplamente segmentada com base em atributos de cor e textura.

4.2 PROCESSAMENTO DE IMAGENS

De acordo com Gonzalez e Woods (2010), “A visão é o mais avançado dos nossos sentidos, por isso não é surpreendente que as imagens desempenhem o papel mais importante na percepção humana”.

A visão computacional objetiva emular a visão humana, utilizando um conjunto de métodos para a interpretação automatizada das informações contidas nas imagens (MARENGONI; STRINGHINI, 2009).

Marques Filho e Neto (1999), mencionam que a área de processamento de imagens é de grande interesse por permitir que aplicações manipulem de forma automática, aprimorando as informações pictóricas extraídas de uma cena para que possam ser interpretadas pelo homem. Já Conci e Azevedo (2008), mencionam que o processamento de imagens é parte do estudo da computação gráfica, sendo considerada a manipulação da imagem na forma digital, transformando, realçando ou filtrando suas características para posterior análise.

Gonzalez e Woods (2010), relatam que não estão claros os limites entre o processamento de imagens digitais e a visão computacional, podendo-se considerar a divisão segundo o nível de operações realizadas em:

- **Processo de Baixo Nível**, que envolve as operações mais básicas e primitivas, sendo um pré-processamento de imagens, reduzindo imperfeições, realçando contrastes, aumentando a nitidez. E é caracterizado pelo fato de que a entrada e a saída serem imagens.
- **Processo de Nível Médio**, que envolve as operações de segmentação, de descrição e classificação. E é caracterizado pela entrada ser em geral uma imagem e a saída ser atributos extraídos dessa imagem.
- **Processo de Alto Nível**, que está mais relacionado a visão computacional propriamente dita. E é caracterizado pela análise dos atributos para dar sentido, para dar interpretação mais próxima possível da compreensão humana.

Pedrini e Schwartz (2008), dividem as etapas do processamento de imagens em: aquisição da imagem, pré-processamento, segmentação, extração de características e classificação, como esquematizado na Figura 7.



Figura 7: Etapas do processamento de imagens. Adaptado de PEDRINI e SCHWARTZ , 2008.

Marques Filho e Neto (1999), propõem a definição de um “Sistema de Visão Artificial (SVA) como um sistema computadorizado capaz de adquirir, processar e interpretar imagens correspondentes a cenas reais”, como pode ser observado na Figura 8.

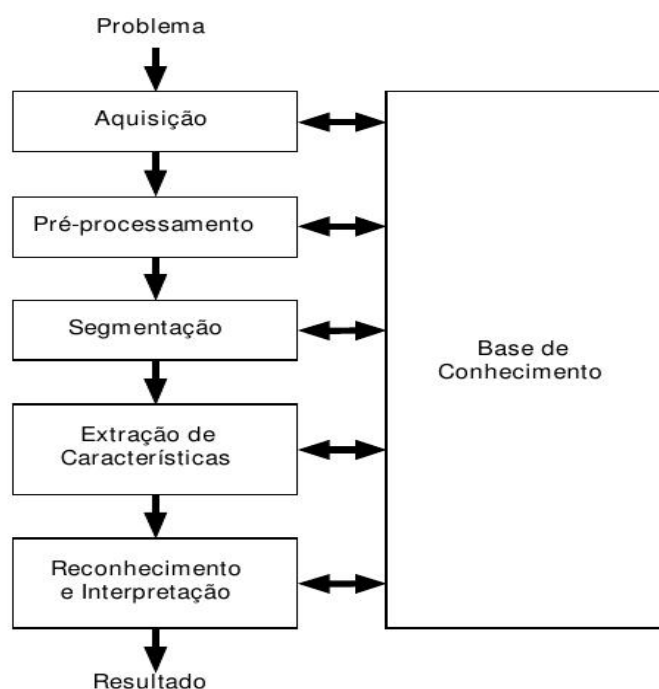


Figura 8: Sistema de Visão Artificial (SVA) e suas principais etapas. MARQUES FILHO e NETO, 1999.

De acordo Marques Filho e Neto (1999), o domínio do problema é a entrada ou conjunto de entradas que serão analisadas pelo SVA e o resultado é a saída dos dados interpretados, sendo que todas as etapas intermediárias terão por objetivo a resolução de um problema específico.

Gonzalez e Woods (2010), mencionam que a aquisição pode ser tão simples quanto receber uma imagem que já esteja em formato digital.

Marques Filho e Neto (1999), completam e apontam que são necessários um sensor e um digitalizador. O sensor é responsável pela captura e conversão da informação óptica em sinal elétrico e o digitalizador pela transformação da imagem analógica em imagem digital.

O pré-processamento tem a função de aprimorar a qualidade da imagem. Nesta etapa são utilizados filtros, ou seja, funções e matrizes matemáticas aplicadas na imagem original para que uma nova imagem seja formada. As transformações ou operações podem ocorrer no domínio espacial e/ou no domínio da frequência. As técnicas aplicadas no domínio espacial baseiam-se em filtros que manipulam o plano da imagem, enquanto que as do domínio da frequência se baseiam em filtros que agem sobre o espectro da imagem (GONZALEZ; WOODS, 2010).

A segmentação é a etapa em que a imagem digital é dividida em múltiplas unidades significativas para a resolução do problema do SVA (MARQUES FILHO; NETO, 1999).

A segmentação é uma das etapas mais importantes do processamento de imagens, envolvendo diversas formas de ser executada, muitas vezes, para um mesmo propósito de análise.

Na extração de características ou atributos, a tarefa é evidenciar as diferenças e similaridades entre os objetos encontrados na fase de segmentação, afim identificar, rotular ou estabelecer padrões de classificação (PRATT, 2001).

O reconhecimento e interpretação é a última etapa do sistema.

No processo de reconhecimento é feita a atribuição de um rótulo a cada objeto segmentado tendo como bases suas características. E na interpretação, o processo consiste em atribuir um significado ao que foi reconhecido (MARQUES FILHO; NETO, 1999).

A base de conhecimento, pode ser considerada como a descrição, o armazenamento das informações adquiridas a cada etapa da resolução do problema (GONZALEZ; WOODS, 2010).

4.2.1 Imagem Digital

Na computação, as imagens podem ser representadas pela forma vetorial onde são construídas a partir de um conjunto de instruções matemáticas ou desenhos geométricos simples como ponto, reta, linha e suas variações em polígonos. Pode ser representado, também, pela forma matricial sendo a forma mais utilizada no processamento de imagens como será observado a seguir (CONCI; AZEVEDO, 2008).

Uma imagem digital pode ser definida por uma função $f(x, y)$, onde x e y representam às coordenadas de um plano bidimensional e o f refere-se ao valor da intensidade ou nível de cinza correspondente ao ponto (GONZALEZ; WOODS, 2010).

Segundo Conci e Azevedo (2009), matematicamente, uma imagem digital pode ser descrita por um conjunto de células em um arranjo espacial bidimensional, ou seja, uma matriz onde cada célula representa os pontos.




Figura 9: Convenção das coordenadas x e y na imagem digital. Adaptado de MARQUES; NETO, 1999.

Como pode ser visto na Figura 9, a origem dos eixos está posicionada no canto superior esquerdo da imagem e representa um espaço finito de pontos. Os pontos ou elementos de imagem são denominados de *pixels* (*picture elements*) na terminologia de imagens digitais (GONZALEZ; WOODS, 2010).

Cada ponto de uma imagem monocromática como indicado na Figura 10, carrega o valor proporcional ao brilho da imagem na coordenada (x, y) . A função f ,

neste caso recebe a denominação L (nível de cinza). Este valor ou intensidade varia entre 0 (pontos mais escuro, L mínimo) e 255 (pontos mais claros, L máximo), sendo sempre positivo (MARQUES; NETO, 1999).




Figura 10: Representação de imagem monocromática.

Nas imagens coloridas como indicado na Figura 11, as informações são armazenadas em intervalos ou bandas de frequência. No padrão RGB, por exemplo, as cores primárias vermelho (R - red), verde (G - green) e azul (B - blue), possuem funções $f(x, y)$ individuais (MARQUES; NETO, 1999).




Figura 11: Representação de imagem no padrão RGB.

Segundo Conci e Azevedo (2008), a conversão de uma imagem colorida em monocromática é chamada de dessaturação.

4.2.2 Sistema de Cores

A cor é um componente de grande importância para qualquer processo de comunicação e compreensão das imagens, podendo resultar quando usada de forma apropriada em uma rápida e correta assimilação da informação (CONCI; AZEVEDO, 2008).

Thomas Young e Hermann von Helmholtz no início do século 19, propuseram a hipótese de que a visão em cores era baseada em três tipos diferentes de receptores especialmente sensíveis luz. Posteriormente chamada de a teoria das três cores ou teoria tricromática, verificou-se que os cones situados na retina eram capazes de perceber as cores vermelha, verde e azul, definidas como cores primárias (KOSCHAN; ABIDI, 2008).

A gama de cores percebidas na luz visível representa uma porção muito pequena do espectro eletromagnético (GONZALEZ; WOODS, 2010).




Figura 12: Intervalo do espectro eletromagnético. ANDREAS e ABIDI, 2001.

A grande variedade de cores visíveis do espectro eletromagnético é o resultado da combinação, da sobreposição, da mistura de quantidades apropriadas das três cores primárias, Figura 12. Esta combinação pode ser aditiva ou subtrativa (PRATT, 2001).

No processo aditivo ocorre a combinação de dois ou mais raios luminosos de frequência diferentes.

No processo de subtração parte da luminosidade é absorvida e a fração percebida pela visão humana é a parte restante que é refletida.

Conforme Gonzalez e Woods (2010), há dois conceitos importantes para o entendimento da cor, sendo eles a luminância e a cromaticidade.

A luminância refere-se à quantidade de cores pretas e brancas presentes na imagem.

A cromaticidade diz respeito a tonalidade da cor, a frequência dominante do raio de luz.

O sistema de cores simplifica a compreensão das propriedades e/ou do comportamento das cores dentro de um contexto particular da percepção humana. Existem vários sistemas de cores, sendo alguns dos principais: o XYZ, o RGB, o HSV e o HLS (CONCI; AZEVEDO, 2008).

Os padrões de maior interesse na detecção de doenças de plantas, abordados neste estudo são o tradicional RGB e o HSV.

4.2.2.1 Padrão de Cores RGB

No padrão RGB as cores são geradas por processos aditivos combinando as cores primárias vermelho, verde e azul.

Este padrão se baseia no modelo natural da visão humana sendo este padrão representado em um sistema de coordenadas cartesianas onde os eixos são o R para valores de vermelho, G para valores de verde e B para valores de azul.

A Figura 13 ilustra o sistema de coordenadas do padrão RGB.




Figura 13: Modelo representativo do espaço de cores RGB.
Adaptado de GONZALEZ e WOODS, 2010.

4.2.2.2 Padrão de Cores HSV

Conci e Azevedo (2008), apontam que o olho humano não é capaz de descrever toda a gama de densidades espectrais visíveis.

Para contornar este problema, técnicas de colorimetria são usadas para descrever a cor segundo sua propriedade.

O matiz (H - Hue) é a propriedade que caracteriza o comprimento de onda dominante da cor.

A saturação (C - Chroma) é a propriedade que mede a pureza, que indica a proporção da cor.

E o brilho (V - Value) é a propriedade indica o grau de intensidade de luz refletida pela cor.

A forma de modelagem do espaço de cores descrita acima é conhecida dos estudos de Munsell e Ostwald e recebe a notação simbólica em português de HSV.

A Figura 14 ilustra o padrão de cores HSV.




Figura 14: Modelo de representação do padrão HSV. CONCI e AZEVEDO, 2008.

4.2.3 Segmentação

A segmentação é o processo de divisão de uma imagem em múltiplas regiões ou áreas de interesse com base em semelhança e homogeneidade de características específicas, objetivando facilitar a sua posterior análise (ANDREAS; ABIDI, 2001).

Segundo Gonzalez e Woods (2010), a segmentação pode se basear em formatos, nas informações contidas nos *pixels* ou em histograma.

O histograma é uma representação gráfica da distribuição de frequências de tons de cinza ou de determinada cor em uma imagem, sendo importante técnica para o cálculo do valor ótimo de limiar de separação dos segmentos (MOREIRA, 2011).

O resultado de uma segmentação poderá servir de entrada ou ponto de partida para outro processo de segmentação, contribuindo desta forma para a base de conhecimento do sistema de visão artificial.

A segmentação de imagens é uma etapa preliminar essencial na maioria dos problemas de reconhecimento de padrões e análise de imagens (GONZALEZ; WOODS, 2010).

4.2.3.1 Limiarização

A limiarização, binarização ou *thresholding* (em inglês), pelo entendimento fácil e simplicidade de implementação é um dos métodos de segmentação mais utilizados.

O algoritmo analisa e substitui o valor de cada pixel da imagem, utilizando uma constante fixa T (limiar) para separação dos segmentos segundo uma regra ou expressão específica. (GONZALEZ; WOODS, 2010).

A expressão de binarização, por exemplo, tem a função geradora da imagem de limiarização $g(x, y)$ igual a um se a função $f(x, y)$ for maior ou igual a constante T e igual zero caso contrário.

A Figura 15 ilustra um exemplo de limiarização.



Figura 15: Exemplo de limiarização de imagem.

4.2.3.2 Segmentação Baseada em Bordas

A segmentação baseada em bordas, é fundamentada na análise de descontinuidades nos níveis de cinza da imagem.

Os pontos de borda são detectados quando ocorrem variações abruptas de níveis de cinza, caracterizando a existência de objetos distintos (QUEIROZ, 2006).

A Figura 16 ilustra a detecção da borda utilizando o algoritmo Canny.




Figura 16: Exemplo de segmentação baseada em bordas.

4.2.3.3 Segmentação Orientada a Regiões

A segmentação orientada a regiões é fundamentada na similaridade dos níveis de cinza. A partir de um ponto inicial, designado de semente, os *pixels* vizinhos com valores similares são agrupados gerando sub-regiões que irão se destacar o restante da imagem (QUEIROZ, 2006).

A Figura 17, ilustra a segmentação com os algoritmos Sobel e Watershed.




Figura 17: Exemplo de segmentação orientada por regiões.

4.2.4 Extração de Características

A extração de características (*feature extraction*) é o processo que visa reduzir o tamanho das informações.

No caso das imagens tem como objetivo selecionar os dados de maior relevância e agrupá-los em um conjunto mais significativo, mais preciso e mais fácil de ser manipulado. (GONZALEZ; WOODS, 2010)

A etapa de extração de características é importante, pois as imagens normalmente contém muita informação redundante, desnecessária ao propósito da resolução do problema do SVA.

O fato acima pode ser destacado com o desenvolvimento tecnológico dos dispositivos em que a resolução das imagens capturadas tem aumentado de forma significativa, obrigando a otimização cada vez mais eficaz dos dados úteis.

Muitas vezes as imagens são utilizadas em sistemas de análise em tempo real e o grande volume de *pixels* a serem processados pode provocar lentidão e prejudicar o funcionamento adequado da aplicação.

As características mais utilizadas são: cor, forma, tamanho, textura, assim como a combinação de todas elas.

Os atributos de cor são extraídos pelo método de redução de cores. Este é chamado de quantização e tem como objetivo a diminuição do espaço necessário para armazenar ou representar a imagem, facilitando a sua manipulação.

Vale ressaltar que a quantização altera sensivelmente a resolução da imagem.

Outra forma comum na extração por cor é a utilização de estatísticas do canal de cores e o uso variado de padrões representado em histogramas.

A obtenção de características com base em textura é feita por algoritmos e formulações matemáticas que encontram um padrão, um relacionamento entre a distribuição cromática e estrutural, nas faixas ou intervalos dentro matriz da imagem.

Gonzalez e Woods (2010), explicam que embora haja uma definição formal de textura, intuitivamente o descritor fornecerá atributos como suavidade, rugosidade e regularidade.

Na Figura 18, Gonzalez e Woods (2010) apresentam da esquerda para a direita nos quadrados marcados em branco, exemplos de textura suave, rugosa e regular. É importante verificar que mesmo não podendo sentir de forma tátil é possível perceber as características mencionadas no visual.




Figura 18: Exemplo de textura em imagens.
GONZALEZ e WOODS, 2010.

A extração por forma faz uso de algoritmos que evidenciam as bordas, as regiões, os formatos contidos na imagem e apesar de muitas vezes não representar informações visuais ao ser humano são muito relevantes na construção dos vetores de característica.




Figura 19: Exemplo de extração de característica. GONZALEZ e WOODS, 2010.

Na Figura 19 é exemplificado a extração de características aplicando transformação de Fourier. A série de Fourier é uma forma de representação trigonométrica para funções complexas, infinitas e periódicas. No exemplo é mostrado uma imagem (a) que contém objetos distribuídos de forma aleatória e outra imagem (b) com objetos ordenados. Abaixo, respectivamente (c) e (d) mostram o espectro de

Fourier correspondente para cada uma das imagens acima. Este espectro é capaz de mensurar a rugosidade do fundo da imagem que é similar para ambos, podendo ser visualizado pelos aspectos quadriculados, quanto é capaz de exaltar a existência da natureza aleatória dos agrupamentos através da visualização da energia em (c), indicando que os objetos estão dispostos desordenadamente em contraposição aos da imagem (b).

De acordo com Bender (2003), boa parte dos sistemas de processamento de imagens, inicialmente obtêm um vetor de características que identifica uma ou mais propriedades da imagem, armazena-o e posteriormente o utiliza para comparar com o outro vetor obtido de uma imagem teste para as mesmas propriedades.

Quanto mais próximas ou similares forem os vetores, maiores serão as chances da imagem teste pertencer ao mesmo grupo da imagem inicial, ou seja, possuírem as mesmas características.

Esse agrupamento é chamado de classificação.

4.2.5 Classificação

Gonzalez e Woods (2010), evidencia que somente a extração de atributos ou propriedades é insuficiente para um classificador automático, sendo necessário a seleção correta das características a fim de que estas tenham um bom grau de separabilidade entre as classes. Evidencia, também, que vetores de características podem ser gerados de muitas formas, sendo mais eficiente o uso de descritores como componentes desses vetores.

Os descritores, podem ser definidos como partes das características extraídas que não sofrem variação, sendo uma espécie de “assinatura fina” dos objetos analisados.

Os descritores podem ser globais ou locais. Os globais são calculados através das características tradicionais como cor, textura e/ou forma. E os locais são calculados em regiões ao redor de pontos de interesse na imagem e possuem algoritmos bastante especializados, sendo alguns exemplos: PCA, SIFT, SURF, HAAR, HOG, ORB, entre outros.

Na Figura 20 é ilustrada a sequência de passos de uma classificação onde é possível observar a sutileza da extração de características através descritor HOG.

O método de extração de características pelo histograma de gradientes orientados (do inglês *histogram of oriented gradients*, HOG), baseia-se na contagem de ocorrências de orientação de gradientes localizados na imagem. Os gradientes são vetores que apontam a direção quando ocorrem mudanças nas intensidades dos *pixels*.

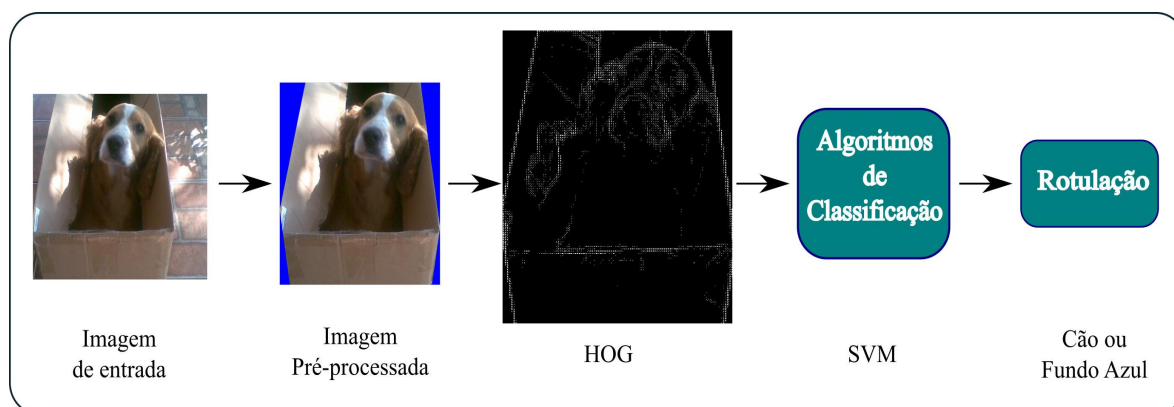


Figura 20: Classificação de objetos em imagens.

Os classificadores podem ser estáticos ou neurais. Os estáticos são muito usados no processamento de imagens e no reconhecimento de padrões, tendo em sua maioria como base a regra de decisão de Bayes.

O Teorema de Bayes, também chamado de Teorema da Probabilidade a Posteriori, baseia-se na probabilidade de um evento ocorrer decorrente de outro evento conhecido *a priori* (FARIAS, 2010).

Nos classificadores neurais, não há a necessidade de nenhuma definição prévia das funções ou extratores de atributos, o fator mais importante refere-se a arquitetura da rede como será abordado adiante.

A classificação pode ser dividida de acordo com o método adotado para treinar os algoritmos de separação em supervisionada e não supervisionada.

Na supervisionada são utilizadas imagens previamente classificadas, objetivando auxiliar o classificador na indicação antecipada das características a observar.

Na classificação não supervisionada o processo será aprendido com o passar do tempo ao executar os algoritmos para um maior número de imagens.

Um dos mais populares algoritmos de classificação supervisionada é o da máquina de vetores de suporte, o SVM (do inglês, *Support Vector Machine*).

O SVM padrão toma como entrada um conjunto de dados e tenta incluir cada entrada em um grupo. Este algoritmo a cada nova entrada busca dividir os grupos de forma a obter as classes mais representativas possíveis (THEODORIDIS, 2003).

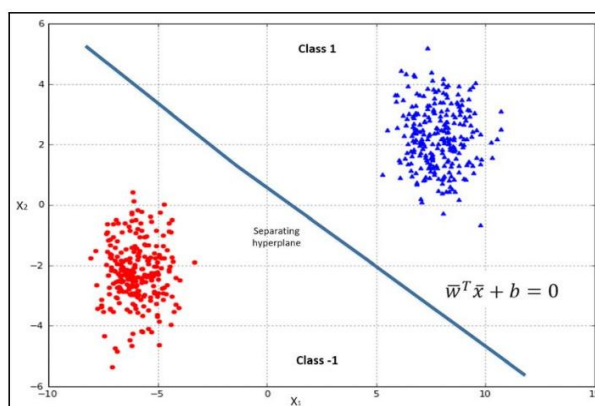


Figura 21: Separação linear de duas classes pela SVM. BONACCORSO, 2017.

A Figura 21 ilustra graficamente o resultado de uma classificação feita por algoritmo de SVM.

Observados os detalhes sobre aquisição da imagem, pré-processamento, segmentação, extração de características e classificação, todos estes relacionados ao processamento de imagens, será abordado outro importante tópico para o SVA que é aprendizagem de máquina.

4.3 APRENDIZAGEM DE MÁQUINA

A Inteligência Artificial (IA) é um tema em amplo desenvolvimento, que envolve diversas áreas do conhecimento.

Na computação, objetiva o desenvolvimento de técnicas de aprendizado, das representações do conhecimento, da capacidade de se adaptar a novas situações e de abstrair as características essenciais do domínio de um problema (LUGER, 2013).

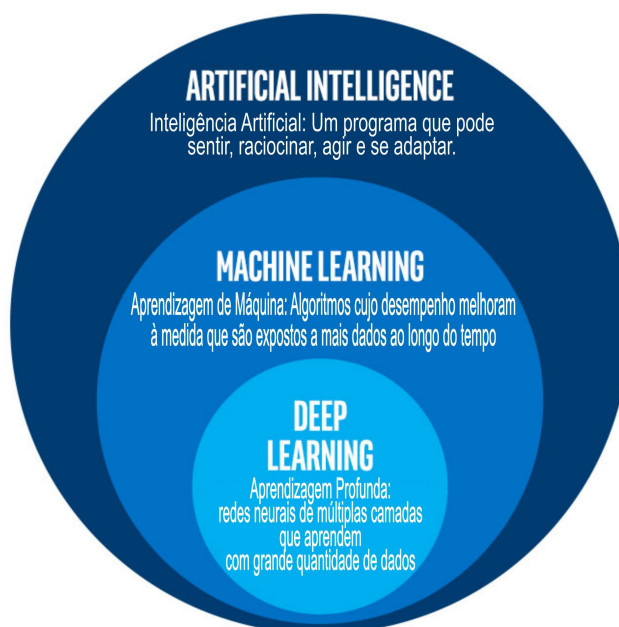


Figura 22: Diagrama de distribuição da Inteligência Artificial.
Adaptado de INTEL AI ACADEMY, 2016.

A Aprendizagem de Máquina (do inglês, *Machine Learning*), é um sub-campo da Inteligência Artificial.

Segundo Tom M. Mitchell (1997): “Diz-se que é um programa de computador que aprende com uma experiência *E*, a partir de alguma classe de tarefas *T* e uma medida de performance *P*, se sua performance nas tarefas em *T*, medidas por *P*, melhoram com a experiência *E*”.

Na *Machine Learning* são utilizados algoritmos de aprendizado para construir um modelo a partir dos dados. Este modelo é aprimorado à medida que é exposto a mais dados e a aferição da performance ao longo do tempo.

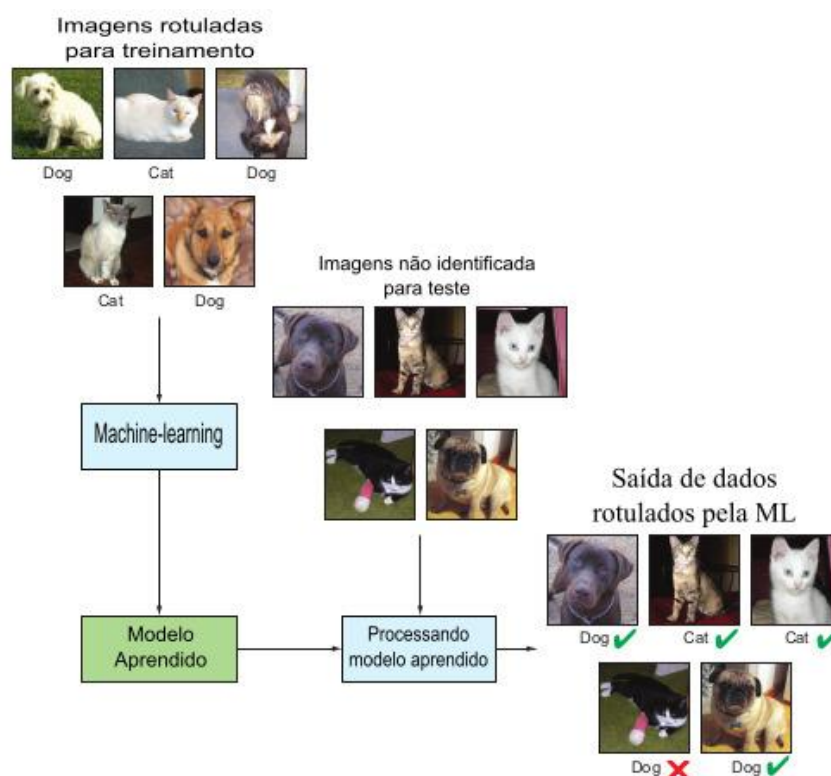


Figura 23: Exemplo de processo de aprendizagem de máquina. Adaptado de BRINK, RICHARDS e FETHEROLF, 2017.

Ampliando o modelo, o nível de abstração e quantidade de dados, tem-se a Aprendizagem Profunda (do inglês, *Deep Learning*) que é uma subcategoria da Aprendizagem de Máquina e que utiliza algoritmos com base em redes neurais (INTEL AI ACADEMY, 2016).

Hierarquicamente, a *Deep Learning* é a forma mais especializada de aprendizagem, sendo relevante onde as características a serem analisadas tornam difícil a identificação ou classificação.

4.3.1 Reconhecimento de Padrões

O reconhecimento de padrões é um subtópico da aprendizagem de máquina, cujo objetivo é classificar informações (GONZALEZ; WOODS, 2010).

Um padrão é um arranjo de características que consegue separar ou ser capaz de classificar um objeto dos demais.

Por outro lado, uma classe é um grupo de padrões que compartilham propriedades similares.

Um objeto é a forma genérica de se referir a uma informação que está sendo categorizada, podendo ser imagens, formas de onda de sinal ou qualquer tipo de medida que possa ser classificada (THEODORIDIS; KOUTROUMBAS, 2003).

4.3.2 Redes Neurais Artificiais

A estrutura de uma Rede Neural Artificial (RNA) tem como base o modelo biológico dos neurônios, no comportamento de aprendizagem destes e na forma de funcionamento de suas interconexões no cérebro (GONZALEZ; WOODS, 2010).

Uma das vantagens das redes neurais artificiais está na capacidade de encontrar soluções para problemas complexos em que os métodos tradicionais ou algoritmos conhecidos não são capazes de resolver.

Um neurônio artificial é constituído por um conjunto de entradas, por um núcleo e pela saída.

Às entradas se associam pesos (W), no núcleo é aplicada uma função de ativação (ϕ) que representa o somatório dos valores das entradas multiplicados pelos pesos e na saída é atribuído o valor obtido (y) que será propagado para os neurônios seguintes. Durante o processo de aprendizagem os pesos são aferidos para que o resultado mais relevante seja computado (HAYKIN, 2008).

A Figura 24 ilustra o esquema de um neurônio proposto por Haykin.

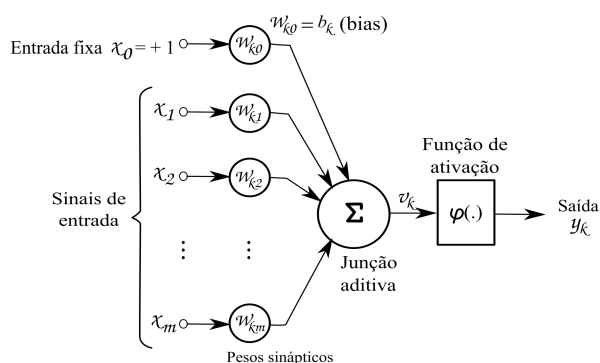


Figura 24: Modelo não-linear de um neurônio.
HAYKIN, 2008.

O modelo computacional de uma rede neural artificial típica (Figura 25) é composta pela entrada de dados, por uma camada de entrada, por uma ou várias camadas intermediárias ou ocultas, pela camada de saída e pela saída dos resultados.

Cada camada é formada por uma quantidade de neurônios artificiais em paralelo, com um número variado de entradas e com um número de saídas igual à dos neurônios.

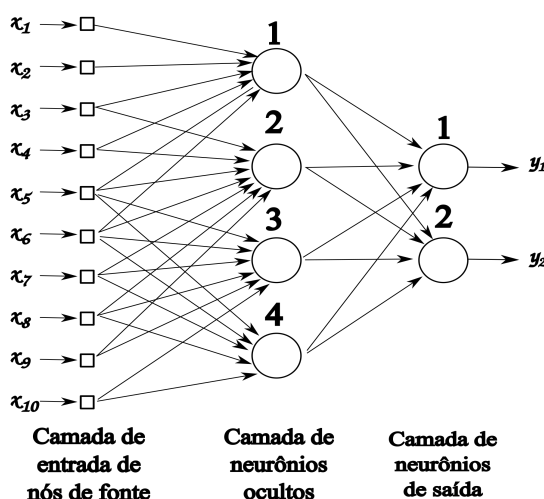


Figura 25: Rede Neural. HAYKIN, 2008.

Há diversos algoritmos de aprendizado, chamados de treino, que diferem basicamente na forma em que os pesos dos neurônios artificiais são ajustados.

Existe o supervisionado, o não supervisionado e o por reforço.

No aprendizado supervisionado é apresentado um conjunto de entradas de treino previamente classificadas que servirão para aferir os pesos.

No aprendizado por reforço para cada entrada apresentada é produzida uma indicação sobre a adequação das saídas correspondentes.

No aprendizado não supervisionado não há um conhecimento prévio da informação de entrada e as saídas não são utilizadas para aferir os pesos. Neste caso os pesos são modificados através do uso de outros métodos e métricas.

Segundo Haykin (2008), a arquitetura da rede neural está intimamente ligada com o algoritmo de aprendizagem usado para treinar a rede e a quantidade de camadas.

As redes podem ter uma ou mais camadas de neurônios. Estas camadas podem ter saídas que retroalimentam a rede ou podem ter saídas que servem de entrada para camada seguinte.

Uma das características das redes neurais de aprendizagem profunda (*Deep Learning*) é ter presente em sua arquitetura múltiplas camadas ocultas.

O modelo mais simples de rede neural é chamado de Perceptron e foi idealizado por Rosenblatt entre meados dos anos 1950 e início dos anos 1960, servindo de base para o desenvolvimento de diversos outros modelos de arquitetura.

O Perceptron aprende uma função de decisão linear que dicotomiza dois conjuntos de treinamento linearmente separáveis, ou seja, é resumidamente um classificador binário (GONZALEZ; WOODS, 2010).

Atualmente diversas arquiteturas estão disponíveis para resolver os mais variados problemas.

Uma delas é a rede neural artificial Perceptron de Múltiplas Camadas (do inglês *Multilayer Perceptron*, MLP) aplicadas frequentemente em problemas de aprendizagem supervisionados servindo de base para outras redes mais complexas como as Redes Neurais Convolucionais.

A MLP é semelhante a uma Perceptron simples, porém possuindo uma combinação destes organizados em um maior número de camadas. Esta rede neural artificial faz uso do algoritmo de retropropagação do erro (*backpropagation*).

O *backpropagation* consiste em duas etapas de processamento. Primeiro uma entrada é aplicada à rede neural e seu efeito é propagado camada a camada tendo os pesos mantidos fixos, posteriormente é obtido um valor do erro na saída e

este é propagado no sentido reverso ajustando os pesos e aferindo toda a rede (HAYKIN, 2008).

4.3.2.1 Rede Neural Convolucional

Uma Rede Neural Convolucional (do inglês *Convolutional Neural Network*, CNN), é uma variação das redes Perceptrons de Múltiplas Camadas, tendo como inspiração o processo biológico da visão humana. Uma CNN é capaz de aplicar filtros em dados visuais, mantendo a relação de vizinhança entre os *pixels* da imagem ao longo do processamento da rede (VARGAS; PAES; VASCONCELOS, 2016).

Durante o processo de treinamento das CNN, os filtros são ajustados automaticamente para que as características mais relevantes sejam analisadas e mantenham de forma invariável as informações repassadas a cada nova camada.

Uma CNN é composta por uma camada de convolução (*Convolutional Layer*), uma cada camada de subamostragem (*Subsampling Layers* ou *Pooling Layers*) uma camada chamada de RELU e uma camada totalmente conectada (Fully Connected Layers).

Uma convolução em uma imagem digital é uma operação matemática que basicamente aplica na matriz de *pixels* uma outra matriz, chamado de filtro, máscara ou *kernel*, com intuito de extrair as características específicas.

Uma camada de convolução é composta por diversos neurônios artificiais responsáveis por aplicar os filtros de convolução em uma determinada área da imagem. Enquanto na formulação de Perceptrons clássica um neurônio é conectado a todos os neurônios da camada anterior, nas redes neurais convolucionais apenas um subconjunto de entradas é conectado a cada neurônio. Dessa forma é possível realizar a análise de campos receptivos locais. Cada grupo de neurônio irá compor um mapa.(VARGAS; PAES; VASCONCELOS, 2016).

Na camada de *pooling* as saídas resultantes da camada de convolução tem as informações reduzidas em tamanho. A função desta camada é focar nos dados que são realmente importantes para a análise e tornar a manipulação mais fácil.

Na camada totalmente conectada como o próprio nome sugere junta todas as informações coletadas em um único descritor que servirá de entrada para o processo de classificação da imagem.

Uma rede neural convolucional pode ter várias sequências dessas camadas (Figura 26).

Quando várias destas camadas intermediárias são ocultas essas redes recebem a designação de DCNN, ou seja, Rede Neural Convolucional Profunda (*Deep Convolutional Neural Network*, em inglês).

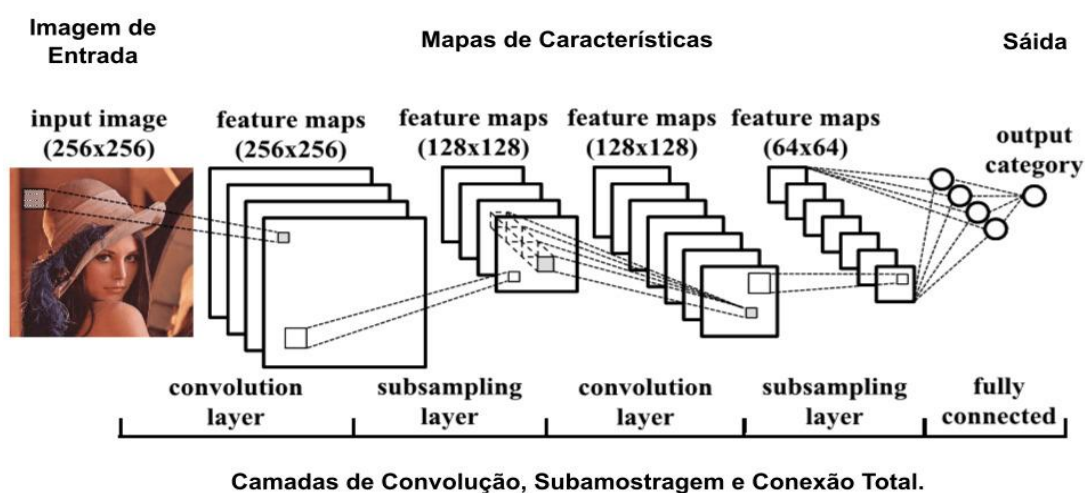


Figura 26: Esquema de uma Rede Neural Convolucional. Adaptado de DATA SCIENCE ACADEMY, 2017.

Na visão computacional é frequente a utilização das Redes Neurais Convolucionais para a classificação de imagens, no reconhecimento de objetos dentro de uma cena, na identificação de faces humanas, no reconhecimento de pedestres e sendo muito útil na detecção de doenças de plantas.

4.3.3 Reconhecimento e Interpretação

Como informado por Gonzalez e Woods (2010) não há um limite claro entre as etapas processamento e as etapas de análise da imagem.

No Sistema de Visão Artificial proposto por Marques Filho e Neto (1999), a última etapa é o reconhecimento e interpretação das informações coletadas.

Ao final do treinamento feito pelos modelos de aprendizagem, as imagens são posta ao algoritmo aprendido para classificação e posterior interpretação dos dados de saída de forma a ser facilmente compreendida pelo homem.

Na Figura 27 pode ser visto um esquema indicando a fase de treinamento em que são utilizados grandes volumes de imagens e a fase de aplicação em que imagens diferentes provenientes de novas entradas são submetidas ao algoritmo aprendido para obtenção das respostas.

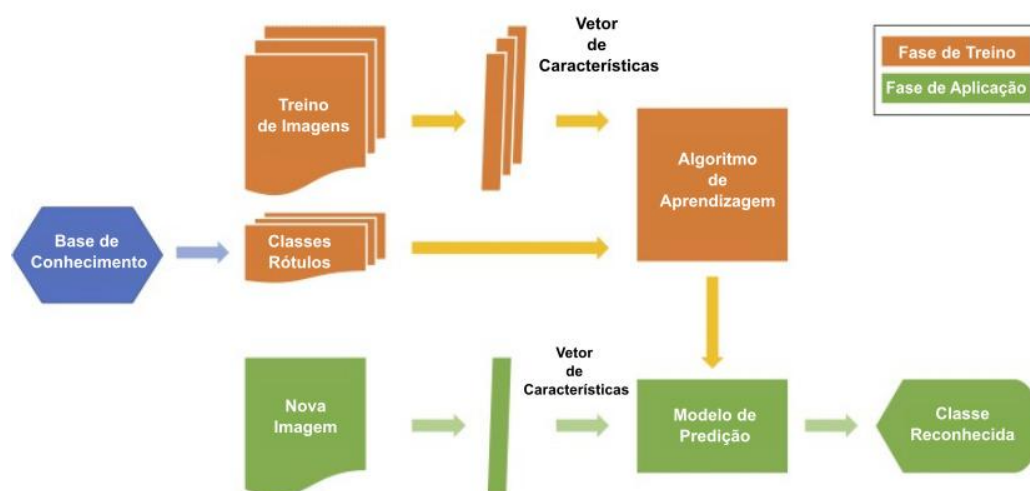


Figura 27: Fases de treino e aplicação da Aprendizagem de Máquina. Adaptado de WÄLDCHEN, 2018.

Observados os principais tópicos do processamento de imagens e da aprendizagem de máquina, a seguir será abordado um processo de detecção de doenças de plantas via imagens digitais.

5 DETECÇÃO DE DOENÇAS DE PLANTAS

Neste capítulo será explanado as etapas de um processo de detecção de doenças de plantas via imagens digitais, observando os pontos mais importantes.

Há várias referências na literatura de como o reconhecimento de imagens pode ser realizado e incluído em sistemas de identificação vegetal.

O processo se resume basicamente na coleta de uma imagem alvo, na execução de um algoritmo de processamento computacional e na saída do resultado do reconhecimento.

No caso da detecção de doenças de plantas através de fotos digitais poderia ser utilizado o esquema ilustrado na Figura 28.

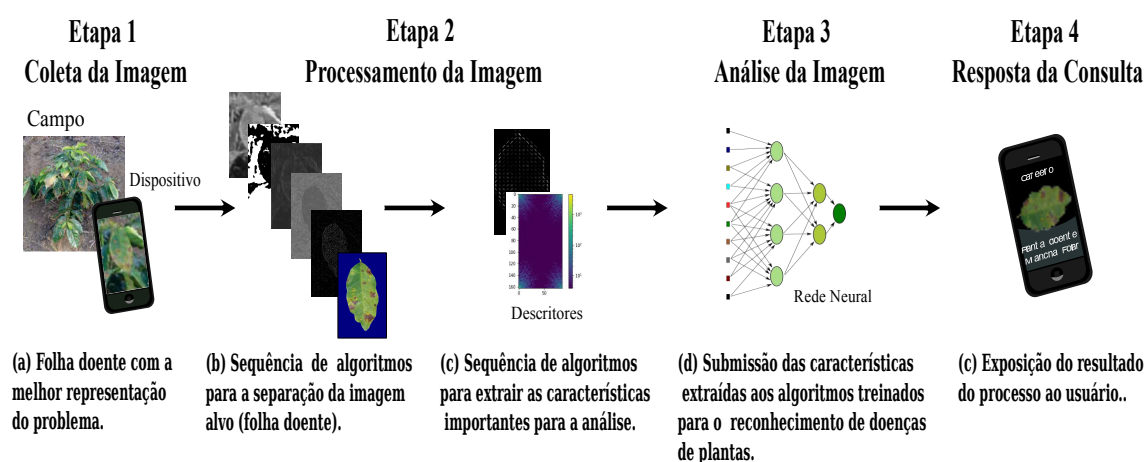


Figura 28: Processo de detecção de doenças em plantas.

O roteiro proposto acima poderia ser totalmente processando em um *smartphone* ou ser dividido em etapas onde a aquisição da imagem seria feita por uma câmera e o processamento da detecção seria executada um microcomputador.

De forma computacional o esquema poderia ser construído seguindo um pseudo-algoritmo como o exemplificado mais adiante.

No algoritmo de Fito Diagnose Digital a entrada poderia ser feita através de um arquivo ou através de uma estrutura contendo a imagem. A resposta final desejada poderia ser a confirmação da doença na folha, a nomenclatura comum da doença identificada e a probabilidade de acerto em que o sistema de análise teria ao processar está entrada específica.

```
// Entrada: Imagem digital de uma folha doente
// Saída: Confirmação e identificação da doença

// Algoritmo de Detecção de Doença de Plantas
Função fitodiagnose() {

    // Etapa 1 - Carregamento da Imagem
    imagem <- ler_arquivo(Imagem)

    // Etapa 2 - Preparação da Imagem - PDI
    imagem_processada <- processar_imagem_digital(imagem)

    // Etapa 2 - Extração de Características - PDI
    vetor_caracteristica <- extrair_dados(imagem_processada)

    // Etapa 3 - Analisar imagem
    resposta[3] <- analisar_imagem(vetor_caracteristica)

    // Etapa 4 - Exibir respostas
    imprimir "Confirmação de doença foliar:", resposta[0] // Positivo ou Negativo
    imprimir "identificação da doença:", resposta[1] // Nomenclatura genérica
    imprimir "Probabilidade de acerto:", resposta[2] // Acurácia da análise
}

Função processar_imagem_digital(imagem) {
    // Redimensionamento da imagem
    imagem <- redimensionar(imagem)
    // Aprimorar imagem
    imagem <- reduzir_interferencias(imagem)
    // Dessaturar
    imagem <- converter_RGB_para_CINZA(imagem)
    // Limiarização
    imagem_binaria <- segmentar_imagem(imagem)
    // Eliminar fundo
    imagem_folha_doente <- aplicar_mascara(imagem_binaria)
    // Retornar imagem de folha doente
    retornar imagem_folha_doente
}

Função extrair_dados(imagem_processada) {
    // Filtros
    filtros[N] <- PCA, SIFT, SURF, HAAR, HOG, ORB, ...
    // Extrair características
    para indice_filtro de 0 até N {
        vetor_caracteristica <- vetor_caracteristica + aplicar_filtro(imagem_processada, filtro[indice_filtro])
    }
    retornar vetor_caracteristica
}

Função analisar_imagem(vetor_caracteristica) {
    // Carregar banco de dados treinado - DataSet
    dados_base <- ler_arquivo(conjunto_dados_treinados)
    // Reconhecer imagem
    resposta[3] <- classificar(vetor_caracteristica, conjunto_dados_treinados)
    // Retornar array com as respostas
    retornar resposta
}

```

A chamada da função principal para a detecção neste hipotético algoritmo seria através da função "fitodiagnose".

O processo de detecção como sugerido no roteiro da Figura 28, independente do equipamento computacional a ser utilizado teria como ponto de partida a coleta da imagem alvo, ou seja, a folha com evidências visuais da doença na planta (Etapa 1).

Devido à heterogeneidade do ambiente agrícola, da ampla diversidade de culturas vegetais e dos muitos sintomas causados por fitopatógenos, a etapa da aquisição da imagem da folha doente torna-se muito importante e sensível.

Ambientes com luz solar obstruída por nuvens, cultivos adensados ou folhas molhadas por orvalho são alguns dos exemplos que poderiam interferir em uma boa coleta de imagem.

No que se refere ao processamento da imagem, existem várias formas de coletar os dados digitais em uma fotografia. Estes poderiam ser providos de uma foto global da planta, de uma foto de folha individual ao natural e até de uma folha ou planta expostas a um ambiente fotográfico controlado.

O importante na etapa da aquisição da imagem digital é o quanto a coleta pode ser significativa e facilitar os processos seguintes de análise.

Alguns fatores a considerar ao fotografar uma folha doente são:

- Luminosidade ambiente;
- Posição da folha na planta;
- Face da folha afetada;
- Estágio e tamanho da folha;
- Densidade de plantas ao redor ou imagem de fundo;



Figura 29: Doenças Foliares. MESQUITA, 2016.

A Figura 29, ilustra alguns dos fatores relevantes na coleta da imagem. Neste exemplo são vistos uma planta e folhas doentes fotografadas em ambiente controlado. Nas fotos foi usado um fundo de cor neutra, não natural para ressaltar as características da folha doente, no caso a imagem alvo. É ilustrado, também, que a simples posição e a face da folha podem determinar diferentes níveis de análise.

Outro exemplo de como a coleta é importante pode ser visto na imagem da Figura 30. Nesta foto o tamanho da folha, a forte influência do fundo da imagem e a presença de um buraco no limbo poderia causar erros nas respostas ao usuário caso os algoritmos de processamento e análises responsáveis pelo tratamento não fossem adequados.




Figura 30: Aquisição de imagem de folha via foto digital.

Sendo assim, muitas vezes o sistema ou aplicação responsável pela detecção quando implementados deverão considerar informações complementares como: o tipo de planta, o estágio de desenvolvimento, a data ou estação do ano, a região, o microclima local, entre outras características relevantes para a obtenção da resposta mais adequada.

Estes sistemas ou aplicações também, teriam que levar em consideração as habilidades e os conhecimentos do usuário final visto que um dos benefícios do uso da detecção automatizada seria a de facilitar e agilizar a consulta técnica.

Na etapa seguinte estando a foto disponível, seriam feitas as operações de pré-processamento, iniciando a Etapa 2 do roteiro de detecção de doenças de plantas.

Durante o pré-processamento operações seriam executadas para eliminar interferências, aprimorar a qualidade da imagem, reduzir ao máximo os eventuais problemas carregados ao fotografar a folha doente.

Na Figura 31 é ilustrado como a aquisição da imagem pode tornar o pré-processamento mais trabalhoso. Nesta podem ser vistas situações onde o refinamento da imagem de entrada se faz necessário. Nos itens (a) e (b) são mostrados como a redução da interferência é importante e nos itens (c) e (d) como o uso de uma delimitação maior da imagem alvo faz toda a diferença.

(a) Original, fotografada utilizando fundo de cor neutra.



Mancha-da-folha (*Bipolaris* sp.) em *Maranta leuconeura*

(b) Original com distorção (ruído).



(c) Folha individualizado com editor de imagens. (d) Planta ao natural com folhas doentes.




Figura 31: Pré-processamento de imagem de folhas. Adaptado de FRUPEX, 1995.

Tendo encerrado o pré-processamento, o próximo passo seria separar a imagem da folha doente do restante (fundo da foto).

É na segmentação da foto focando na folha doente que ocorre o trabalho mais árduo da etapa de processamento da imagem digital.

No ambiente natural as folhas e os sintomas das doenças tem diversas formas, tamanhos, texturas e cores o que acarreta dificuldades na elaboração e no ajuste do algoritmo de segmentação. Junte-se ainda as dificuldades externas como variações de luminosidade e sombreamento que podem modificar as características visuais da folha doente.

Por esta razão a segmentação é muito importante para a uma boa base de conhecimento e para a resolução de um problema de SVA ligado a plantas.

Como não há um único caminho ou modelo de procedimentos específicos que atendam de forma simples e rápida o processo de detecção de doenças em plantas na Figura 32 são ilustrados os passos a serem seguidos para segmentar a parte saudável do limbo foliar, da parte que contém as manchas ou sintomas da doença.




Figura 32: Exemplo de segmentação em folhas.

Como primeiro passo a imagem da folha original (a) seria dessaturada. Depois a imagem resultante em tons de cinza (b) seria binarizada usando um valor para a constante de limiarização capaz de separar o fundo da folha, gerando ao final uma máscara ou silhueta (c). Paralelamente, uma cópia da imagem original (a) seria convertida do padrão de cores RGB para o HSV (d). Esta por sua vez seria também

limiarizada, mas desta vez utilizando um método de separação com base em histograma do padrão de cores HSV, gerando outra máscara. O padrão HSV, é muito útil, pois possibilita separar as partes em tons de cor verde das demais cores. Como passo final seria aplicado as máscaras obtidas de ambas limiarizações na imagem original, através de operações lógicas entre as matrizes, resultando nas imagens contendo as partes saudáveis (e) e contendo as manchas causadas pela doença (f).

Como pode ser visto, o processo de segmentação requer vários passos intermediários para extrair as informações desejadas.

Mesmo com todo o cuidado na escolha dos algoritmos de segmentação ainda assim, podem ocorrer situações em que não é possível concluir plenamente a separação. Isso pode ocorrer, por exemplo, quando a folha tiver baixo ou nenhum pigmento verde ou quando o limbo contiver furos que extravasam o fundo da foto.

Por outro lado, o método de segmentação como ilustrado acima poderia ser utilizado para mensurar as áreas lesionadas, ressaltar as doenças ou servir de estágios preparatórios para extração de outras características.

Uma das dificuldades em ajustar o procedimento de segmentação está no fato de que não há na natureza apenas espécies de plantas com folhas verdes e de que o estágio de desenvolvimento pode alterar a tonalidade do verde.

Na figura 33 é possível visualizar a dificuldade em tratar imagens com folhas coloridas ou plantas que possuem variação, ou seja, folhas manchadas e folhas verdes em um mesmo espécime vegetal causada por mutação genética espontânea.



Figura 33: Desafios da segmentação de imagem de folhas vegetais.

Na Figura 33, a esquerda é mostrada a diferenças de cores das folhas de uma única Cheflera e a direita a ausência de cor verde aparente, na folha do Cróton.

Ambas plantas ornamentais que exemplificam como o universo das folhas pode dificultar a aferição da segmentação.

Feitas as devidas segmentações da imagem de entrada evidenciando as partes ou propriedades que seriam foco da resolução do problema, o próximo passo seria a otimização dos dados através da extração de características específicas.

Na detecção de folhas doentes, várias características poderiam servir de interesse para a extração, a primeira delas como indicada na segmentação seria a presença ou não de lesões, a presença ou não de manchas de tons diferentes a do limbo foliar.

Outra forma seria utilizar a extração de características por funções matemáticas como da transformação de Fourier (FFT), para diferenciar a presença de uma folha sadia de uma folha com sintomas de doença. A presença de manchas ou não poderiam ser detectadas pela frequência de tons de verde contidas em cada imagem e exaltadas nas saídas dos gráficos de uma FFT, como pode ser observado na Figura 34 que ilustra como seria o resultado da aplicação desse algoritmo.

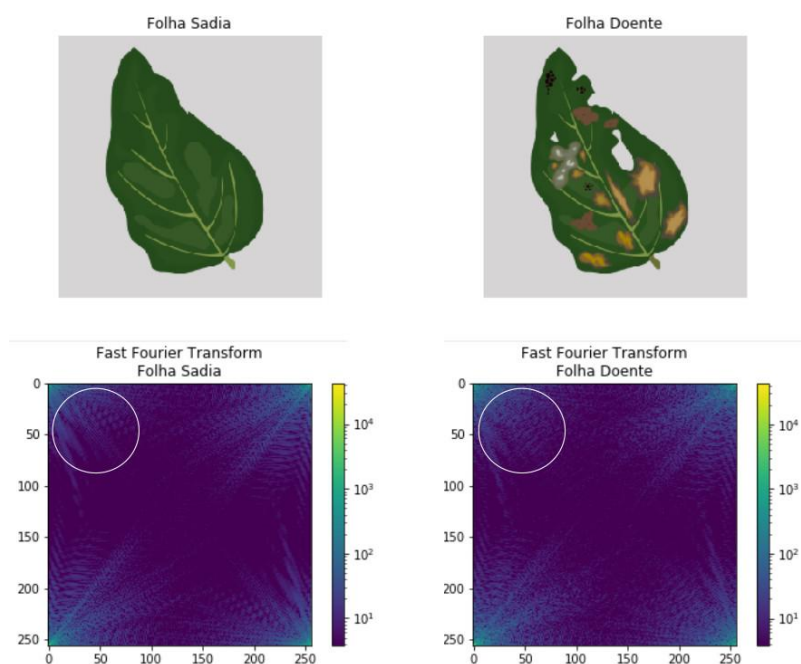


Figura 34: Extração de característica usando FFT.

Outra forma possível seria marcar a imagem utilizando algoritmos que ressaltassem as cores ou formatos das manchas ou lesões causadas pelas doenças para posterior extração dos atributos.

A Figura 35 ilustra como as manchas foram poderiam ser encontradas após passar por um processo de segmentação, por alterações morfológicas, por obtenção dos pontos de borda e finalmente pela marcação na imagem original dos contornos sinalizados em cores contrastantes e diferentes das cores predominantes no limbo foliar.



Figura 35: Exemplo de detecção de contornos para extração de atributos.

Assim como na segmentação, há várias formas de se obter extratores de características para serem utilizados no reconhecimento e classificação.

Muitas vezes são necessário uma combinação de vários destes extratores para atingir o objetivo final ou parte deste no processo de análise.

A detecção por descritores, por exemplo, poderia ser útil ao reconhecer os padrões de um objeto do tipo mancha foliar, do tipo nervura, do tipo limbo foliar ou da textura de uma folha doente.

Na Figura 36 é ilustrado a utilização do detector-descritor ORB com o objetivo de identificar similaridades entre duas imagens. No caso particular se fosse necessário selecionar folhas de formatos diferentes ou caso se desejasse verificar onde está a nervura da folha este descritor poderia auxiliar no processo.




Figura 36: Detecção de padrões.

Vista algumas possibilidades de segmentação e extração de atributos, a partir deste ponto estaríamos entrando na Etapa 3 do roteiro sugerido na Figura 28, esta referente a análise de imagens.

Não há, como destacado no Capítulo 4 uma divisão clara entre as etapas de processamento de imagens e de análise de imagens. Muitos dos conceitos vistos até o momento podem fazer parte de passos específicos e individualizados ou de um conjunto destes inseridos dentro de um modelo mais amplo de processamento e análise.

Até este ponto, resumidamente teríamos coletado a imagem, feito o pré-processamento, feito a separação do objeto ou imagem alvo via da segmentação e eleito algumas características interessantes para o processo de detecção. O próximo passo seria em direção da identificação da doença.

Antes de prosseguir na explanação é necessário apontar algo importante sobre o passo de classificação. Como visto nos fundamentos teóricos a classificação é o ato de agrupar os objeto colocados em processamento, feitos por algoritmos simples como uma SVM ou complexos como uma DCNN, por exemplo.

Para o propósito da detecção de doenças em plantas a etapa de classificação de uma folha doente, dependerá inicialmente do método a ser utilizado e de qual resposta seria esperada.

Quando analisadas folhas de uma mesma espécie vegetal, previamente segmentadas para evidenciar o limbo foliar, poderia ser utilizado a classificação por métodos menos complexos e de mais fácil implementação como os SVM.

Nesta ideia, seria necessário responder simplesmente se a planta ou folha está ou não doente.




Figura 37: Classificação de folhas normais das doentes.

Neste tipo de classificação teríamos uma divisão como a ilustrada na Figura 37, onde a cada nova entrada ou imagem esta seria submetida a todas as etapas de preparação e processamento de imagem e depois a um agrupamento e classificação feito pelo algoritmo de SVM treinado previamente.

Caso o desejo da análise fosse obter respostas mais precisas ou mais elaboradas como qual a doença estaria sendo apresentada na imagem ou qual a cultura estaria relacionada o mais indicado seria lançar uso da aprendizagem de máquina.

O trabalho de Fuentes (2018), por exemplo, demonstra o uso de redes neurais artificiais para a classificação e reconhecimento de pontos doentes no limbo

foliar. O que pode ser observado na Figura 38 em que são apresentados as saídas ao aplicar modelo ou algoritmo de reconhecimento aprendido.



Figura 38: Reconhecimento de padrões para detecção e classificação. FUENTES, 2018.

Vale ressaltar que independente do modelo de classificação utilizado é necessário um alto grau de treino e aferição dos dados de aprendizagem para que as respostas sejam satisfatórias.

Vários trabalhos também, indicados no Capítulo 2 fazem ressalvas quanto ao volume de imagens usadas para a treino dos modelos de aprendizagem.

Estes relatam que quanto maior for o conjunto de dados para treino mais eficazes serão os resultados apresentados na saída.

No momento, este é uns dos desafios para o avanço da visão computacional aplicada a agricultura e as plantas. Somente recentemente surgiu o interesse em coletar imagens de plantas com sintomas ou danos para armazenar em bancos de imagens categorizados por cultura, doença e pragas.

Por outro lado, quanto mais abrangente for a quantidade de espécies a serem contempladas pela detecção maior deverá ser o grau de especialização dos modelos de aprendizagem e consequentemente classificação.

Em casos onde as imagens contendo folhas for muito diversificada e a quantidade de doenças a serem detectadas for elevada, seriam necessário modelos de análise mais sofisticados como os das redes neurais Convolucionais.

A rede neural Convolucional, inclusive, foi apontada como o modelo mais mencionado nos trabalhos relacionados no Capítulo 2.

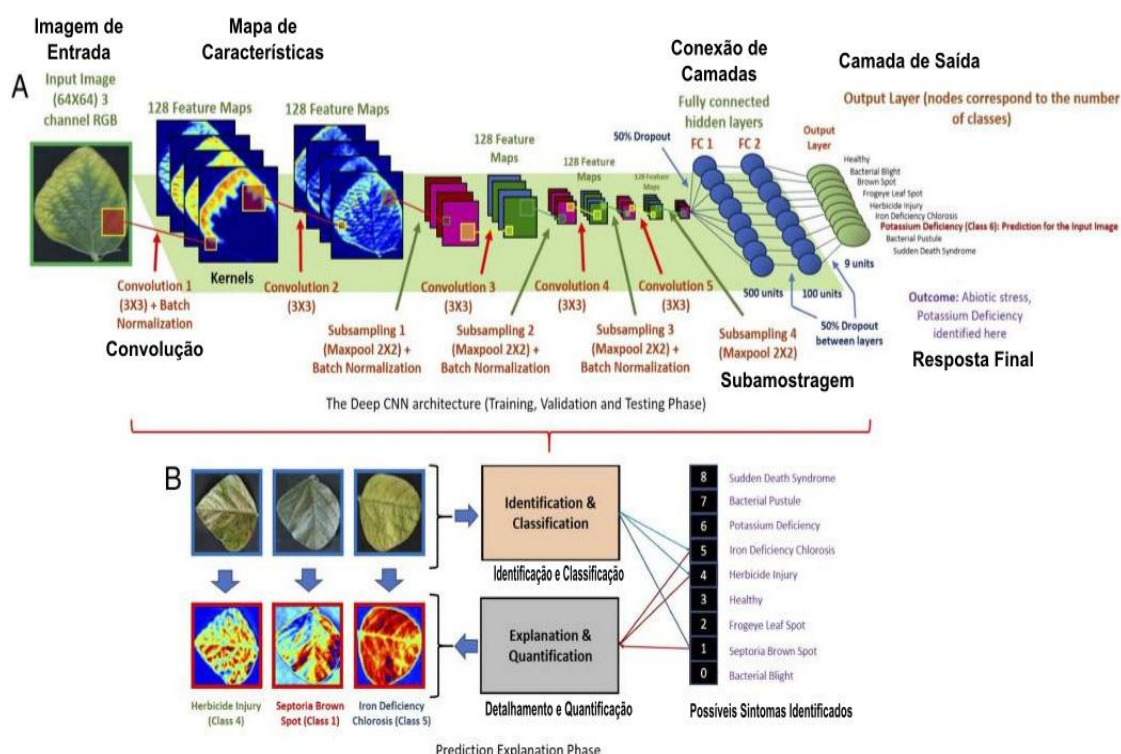


Figura 39: Diagrama ilustrativo de uma Rede Neural Convolucional. Adaptado de GHOSAL, 2018.

Na Figura 39 é mostrado um diagrama de uso de uma rede neural convolucional neste caso profunda, onde (A) representa de forma teórica sua arquitetura e (B) as fases de análise. É possível observar no esquema como se comportam as camadas, passando pelo mapeamento de características, até a saída da resposta da detecção de doenças em plantas.

Terminado o passo de extração de características por meio das convoluções, na camada de saída são obtidos os descritores que poderiam ser úteis, por exemplo, nos algoritmos de identificação embarcados em equipamentos com poucos ou limitados recursos computacionais e de armazenamento.

O grande benefício do processo de aprendizagem de máquina é que uma vez treinado, o algoritmo resultante pode ser reutilizado quantas vezes forem necessárias para identificar um mesmo problema ou pode servir de ponto de partida para ampliar o modelo aprendido diminuindo o trabalho a ser feito pelos pesquisadores.

Conhecidos os vetores de características aprendidos, inclusive os classificadores simples como as SVM poderiam se encarregar de executar a predição e

dizer se a imagem de entrada pertence ou não um determinado grupo de doença de plantas.

A Figura 40 mostra a visualização de características provenientes de uma rede neural convolucional do trabalho realizado por Sladojevic (2016). A imagem de entrada pode ser vista em (a) e as diversas saídas das camadas de convolução nas imagens (b até h). Como pode ser observado algumas informações são incompreensíveis para o ser humano, mas carregam em si os dados mais relevantes para a análise da imagem.

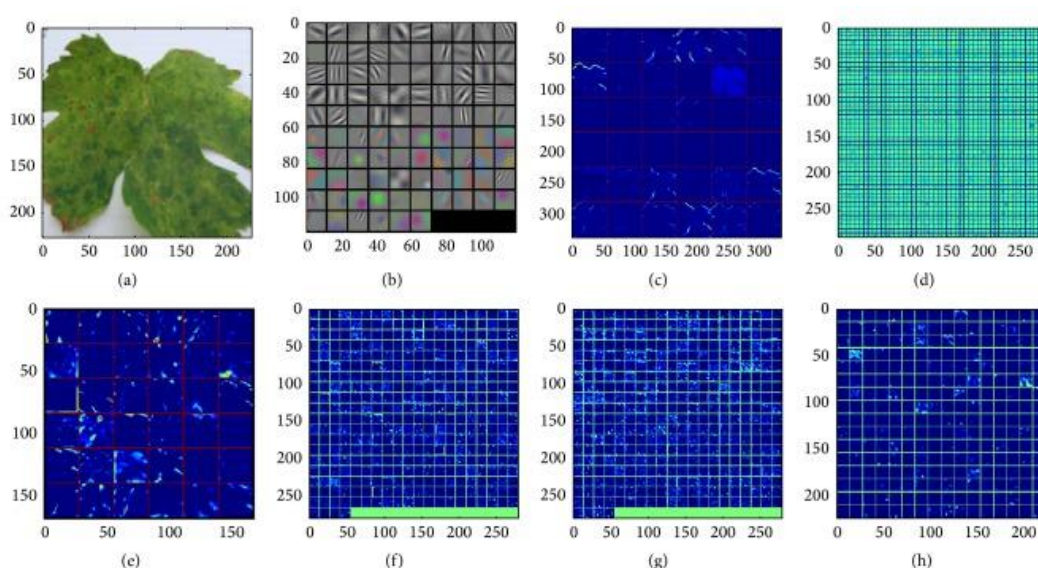


Figura 40: Visualização do treinamento de uma *Deep Learning*. SLADOJEVIC, 2016.

Finalizado a Etapa 3 de análise de imagens a etapa final seria a saída dos resultados, ou seja, as respostas ao usuário. Independentemente da formatação de exibição, o foco de todo o processo seria verificar se a planta está ou não doente ou qual seriam os problemas e as possíveis recomendações ou ações agronômicas a serem postas em prática.

Este trabalho não tem a pretensão de esgotar todos os aspectos de um processo de uma Fito Diagnose Digital ou de sua aplicação prática, mas objetiva relatar a relevância deste tema tão multidisciplinar que está sendo alvo de interesse e estudo de pesquisadores e de desenvolvedores de soluções para agricultura.

CONCLUSÕES E TRABALHOS FUTUROS

Inovações tecnológicas que auxiliem nas demandas cotidianas do homem do campo ou do setor agrário, são sempre muito bem-vindas.

A visão computacional e a aprendizagem de máquina tem valorosa e enorme contribuição no processo automatizado de detecção de doenças de plantas, bem como em várias outras soluções que trabalham com vegetais.

A Fito Diagnose Digital é uma proposta importante ao tornar possível a assistência técnica principalmente para as áreas rurais mais humildes e distantes.

As limitações atuais como a quantidade de espécies vegetais abrangidas pela detecção digital e o número de aplicações móveis disponíveis, serão superadas com o rápido avanço computacional dos equipamentos portáteis, com a otimização dos algoritmos de processamento de imagem e com a maior disponibilidade de fotos digitais de folhas doentes para treinamento de máquina.

A quantidade de trabalhos de pesquisa que estão sendo desenvolvidos para o tema, reforça o valor que a computação tem e que representará no futuro para o agricultor e toda a sociedade.

Como trabalho futuro fica a expectativa da implementação dos conceitos abordados especialmente para a detecção de doenças em plantas ornamentais.

REFERÊNCIAS BIBLIOGRÁFICAS

1. GONZALEZ, Rafael C.; WOODS, Richard E. **Processamento digital de imagens**. 3ª ed. Tradução de Cristina Yamagami e Leonardo Piamonte. São Paulo: Pearson Prentice Hall, 2010.
2. MARENGONI, Maurício; STRINGHINI, Denise. **Tutorial: Introdução à Visão Computacional usando OpenCV**. Revista de Informática Teórica e Aplicada, v. 16, n. 1, p. 125-160, 2009.
3. MARQUES FILHO, Ogê; NETO, Hugo Vieira. **Processamento digital de imagens**. Brasport, 1999.
4. CONCI, Aura; AZEVEDO, Eduardo; LETA, Fabiana R. **Computação Gráfica: Teoria e Prática**. Rio de Janeiro: Campus, 2008.
5. PEDRINI, Hélio; SCHWARTZ, William Robson. **Análise de imagens digitais: princípios, algoritmos e aplicações**. Thomson Learning, 2008.
6. PRATT, Willam K. **Digital Image Processing**. PIKS inside, John Wiley & Sons. Inc Editions, 2001.
7. QUEIROZ, José Eustáquio Rangel de; GOMES, Herman Martins. **Introdução ao processamento digital de imagens**. Revista de Informática Teórica e Aplicada, v. 13, n. 2, p. 11-42, 2006.
8. KOSCHAN, Andreas; ABIDI, Mongi. **Digital color image processing**. John Wiley & Sons, 2008.
9. MOREIRA, A. **Métodos para segmentação binária para imagens em tons de cinza**. Londrina: Laboratório de Física Nuclear Aplicada (LFNATEC), 2011. 28 p.

10. BENDER, Túlio Cléber. **Classificação e Recuperação de Imagens por Cor Utilizando Técnicas de Inteligência Artificial**. Universidade do Vale Do Rio Dos Sinos (UNISINOS). São Leopoldo, 2003.
11. NILSBACK, Maria-Elena; ZISSERMAN, Andrew. **Automated flower classification over a large number of classes**. *Computer Vision, Graphics & Image Processing*. 2008. ICVGIP'08. Sixth Indian Conference on. IEEE, 2008. p. 722-729.
12. FARIAS, Ana Maria Lima de. **Probabilidade e estatística**. v. único. Rio de Janeiro: Fundação CECIERJ, 2010. 374p.
13. BONACCORSO, Giuseppe. **Machine Learning Algorithms**. Packt Publishing Ltd, 2017.
14. LUGER, George F. **Inteligência Artificial**. 6ª ed. Tradução de Daniel Vieira. São Paulo: Pearson Education do Brasil, 2013.
15. MITCHELL, Tom M.. **Machine Learning**. McGraw-Hill, 1997.
16. BRINK, Henrik; RICHARDS, Joseph W.; FETHEROLF, Mark. **Machine Learning**. Manning, 2017.
17. THEODORIDIS, Sergios; KOUTROUMBAS, Konstantinos. **Pattern Recognition**. 2th. Elsevier Academic Press. 2003.
18. HAYKIN, Simon. **Redes Neurais: Princípios e prática**. 2ª ed. Tradução de Paulo Martins. Porto Alegre: Engel. Artemed Editora S.A, 2008.
19. VARGAS, Ana Caroline Gomes; PAES, Aline; VASCONCELOS, Cristina Nader. **Um estudo sobre redes neurais convolucionais e sua aplicação em detecção de pedestres**. *Proceedings of the XXIX Conference on Graphics, Patterns and Images*. 2016. p. 1-4.

20. DE NAZARÉ JÚNIOR, Antonio Carlos et al. **Detecção Automática da Área Foliar Danificada da Soja através de Imagens Digitais**. Brasil: Conference on Graphics, Patterns and Images (SIBGRAPI). 2009.
21. GALVÃO, Geferson et al. **VISÃO COMPUTACIONAL PARA DETECÇÃO DE DOENÇAS FÚNGICAS NA AGRICULTURA**. ÚNICA Cadernos Acadêmicos, v. 2, n. 1, 2018.
22. EMBRAPA. **Visão 2030: o futuro da agricultura brasileira**. Brasília, DF: Embrapa, 2018. 212p
23. SOFTEX. **CADERNOS TEMÁTICOS DO OBSERVATÓRIO: TIC NO AGRO-NEGÓCIO**. Associação para Promoção da Excelência do Software Brasileiro (SOFTEX), Campinas, SP. 2016
24. MAZOYER, Marcel e ROUDART, Laurence. **História das Agriculturas do Mundo: do neolítico à crise contemporânea**. Tradução de Cláudia F. Falluh Balduino Ferreira. – São Paulo: Editora UNESP; Brasília, DF: NEAD, 2010. 568p
25. ALBUQUERQUE, Marcos Cintra Cavalcanti de; NICOL, Robert. **ECONOMIA AGRÍCOLA: O SETOR PRIMÁRIO E A EVOLUÇÃO DA ECONOMIA BRASILEIRA**. McGraw-Hill, São Paulo, 1987
26. PETERSEN, P.; WEID, J.M von der; FERNANDES, G.B. **Agroecologia: reconciliando agricultura e natureza**. Informe Agropecuário. Belo Horizonte, EPA-MIG, v.30, n. 252, p. 7-15, set/out. 2009
27. BOSERUP, E. **Evolução agrária e pressão demográfica**. São Paulo: Hucitec, 1987. 141p.
28. MASSRUHÁ, Silvia Maria F.S.; LEITE, Maria Angélica de A.; MOURA, Maria Fernanda. **Os novos desafios e oportunidades das tecnologias da informação e da comunicação na agricultura (AgroTIC)**. Tecnologia da informação e comunicação e suas relações com a agricultura. EMBRAPA, Brasília, DF, 2014. p. 23-38

29. TING, K.C.; ABDELZAHER. T.; ALLEYNE, A.; RODRIGUEZ L. **Information technology and agriculture: global challenges and opportunities**. The Bridge, Washington, D.C., v. 41, n. 3, p. 6-13, 2011.
30. MASSRUHÁ, Silvia Maria F.S.; LEITE, Maria Angélica de A.; EVANGELISTA, Silvio Roberto. M.; SOUZA, Kleber X. S. de. **Tecnologias emergentes - futuro e evolução tecnológica das AgroTIC. Tecnologia da informação e comunicação e suas relações com a agricultura**. EMBRAPA, Brasília, DF, 2014. p. 331-349
31. BARBEDO, Jayme G. A.; MEIRA, Carlos Alberto A. **TIC na segurança fitossanitária das cadeias produtivas. Tecnologia da informação e comunicação e suas relações com a agricultura**. EMBRAPA, Brasília, DF, 2014. p. 95-189
32. LOPES, C. A.; AVILA, A. C. **Doenças do tomateiro**. Brasília, DF: Embrapa Hortaliças, 2005.
33. ZAMBOLIM, L.; LOPES, C. A.; PICANÇO, M. C.; COSTA, H., **Manejo integrado de doenças e pragas hortaliças**. Viçosa: Universidade Federal de Viçosa, 2007.
34. JÚNIOR, Trazilbo José de Paula; VENZON, Madelaine; TEIXEIRA, Hudson; PALLINI, Angelo. **Agroecologia: reconciliando agricultura e natureza**. Informe Agropecuário. Belo Horizonte, EPAMIG, v.30, n. 252, p. 51-57, set/out. 2009
35. REIS, Simone Novaes; RESENDE, Mário Lúcio Vilela de; SOUZA, Ricardo Magela de; ALMEIDA, Elka Fabiana Aparecida. **Floricultura: tecnologias, qualidade e diversificação**. Informe Agropecuário. Belo Horizonte, EPAMIG, v.30, n. 249, p. 47-55, mar./abr. 2009
36. FRUPEX. **PROGRAMA DE APOIO À PRODUÇÃO E EXPORTAÇÃO DE FRUTAS HORTALIÇAS FLORES E PLANTAS ORNAMENTAIS (BRASIL), Flores e plantas ornamentais para exportação: aspectos fitossanitários**. Brasília, DF: Ministério da Agricultura, do Abastecimento e da Reforma Agrária, Secretaria de Desenvolvimento Rural, Programa de Apoio à Produção e Exportação de Frutas Horta-

liças, Flores e Plantas Ornamentais. EMBRAPA, 1995, Série Publicações Técnicas FRUPEX, 17.

37. CAROLLO, Eliane M.; FILHO, Hermes P. S.. **Manual básico de técnicas fitopatológicas**. Cruz das Almas: Embrapa Mandioca e Fruticultura BA, 2016.

38. AGRIOS, George. N. **Plant Pathology**. 5th ed. Elsevier Academic Press, Burlington, 2005.

39. SANTOS, Thiago Teixeira; YASSITEPE, Juliana Erika de C.T.. **Fenotipagem de plantas em larga escala: um novo campo de aplicação para a visão computacional na agricultura. Tecnologia da informação e comunicação e suas relações com a agricultura**. EMBRAPA, Brasília, DF, 2014. p. 85-100.

40. MESQUITA, Carlos Magno de et al. **Manual do café: distúrbios fisiológicos, pragas e doenças do cafeeiro (Coffea arábica L.)**. Belo Horizonte: EMATER-MG, 2016.

41. VENZON, M.; PAULA JÚNIOR, T. J. de; PALLINI, A. **Controle alternativo de pragas e doenças**. Viçosa/MG: EPAMIG/CTZM, 2005. p.188.

42. AMORIM, L.; REZENDE, J. A. M.; BERGAMIM FILHO, A. **Manual de fitopatologia: Princípios e Conceitos**. 4. ed. v. 1. Piracicaba: Agronômica Ceres, 2011.

43. VIDAL, W.N.; VIDAL, M. R. R. **Botânica – Organografia: Quadros Sinóticos Ilustrados de Fanerógamos**. Viçosa: UFV, 2007.

44. OPENCV. **"OpenCV Tutorials"**. Disponível em <https://docs.opencv.org/3.4.2/d9/df8/tutorial_root.html> acessado em 21 de agosto de 2018.

45. SCIKIT-LEARN, **"scikit-learn Tutorials"**. Disponível em <<https://scikit-learn.org/stable/tutorial/index.html>> acessado em 07 de novembro de 2018

46. SCIKIT-IMAGE. **"User Guide"**. Disponível em <http://scikit-image.org/docs/stable/user_guide.html> acessado em 07 de novembro de 2018

47. INTEL AI ACADEMY. **"How to Get Started as a Developer in AI."**, Outubro/2016. Disponível em <<https://software.intel.com/en-us/articles/how-to-get-started-as-a-developer-in-ai>> acessado em 17 de outubro de 2018.

48. MOHANTY, Sharada P.; HUGHES, David P.; SALATHÉ, Marcel. **"Using Deep Learning for Image-Based Plant Disease Detection."** Frontiers in Plant Science 7 , 2016. Disponível em <<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5032846/>> acessado em 22 de outubro de 2018.

49. FUENTES, Alvaro et al. **"A Robust Deep-Learning-Based Detector for Real-Time Tomato Plant Diseases and Pests Recognition."** Sensors (Basel, Switzerland) , 2017. Disponível em <<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5620500/>> acessado em 22 de outubro de 2018.

50. PEREZ-SANZ, Fernando; NAVARRO, Pedro J.; EGEA-CORTINES, Marcos. **"Plant Phenomics: An Overview of Image Acquisition Technologies and Image Data Analysis Algorithms."** GigaScience, 2017, Disponível em <<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5737281/>> acessado em 22 de outubro de 2018.

51. SLADOJEVIC, Srdjan et al. **"Deep Neural Networks Based Recognition of Plant Diseases by Leaf Image Classification"**. Computational Intelligence and Neuroscience, 2016. Disponível em <<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4934169/>> acessado em 07 de novembro de 2018.

52. GHOSAL, Sambuddha et al. **"An explainable deep machine vision framework for plant stress phenotyping"**. 2018. Disponível em <<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5939070/>> acessado em 27 de novembro de 2018.

53. WÄLDCHEN, Jana et al. **"Automated plant species identification - Trends and future directions"**. 2018. Disponível em <<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5886388/>> acessado em 29 de novembro de 2018.

54. SUN, Yu et al. "**Deep Learning for Plant Identification in Natural Environment**". 2017. Disponível em <<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5458433/>> acessado em 30 de novembro de 2018.
55. MICHAELIS, **Dicionário Brasileiro da Língua Portuguesa**, Editora Melhoramentos Ltda., 2015, Disponível em <<https://michaelis.uol.com.br/moderno-portugues/busca/portugues-brasileiro/agricultura/>> acessado em 30 de setembro de 2018.
56. LOPES, Mauricio Antônio. "**Uma Indústria chamada Agricultura**". Portal do Agronegócio, 2013. Disponível em <<https://www.portaldoagronegocio.com.br/artigo/uma-industria-chamada-agricultura-3566>> acessado em 13 de outubro de 2018.
57. Ministério da Agricultura, Pecuária e Abastecimento (MAPA). "**Agropecuária puxa o PIB de 2017**". Portal do MAPA, 2017. Disponível em <<http://www.agricultura.gov.br/noticias/agropecuaria-puxa-o-pib-de-2017>> acessado em 13 de outubro de 2018.
58. PLANTVILLAGE. Disponível em <<https://plantvillage.psu.edu/>> acessado em 22 de outubro de 2018.
59. DATA SCIENCE ACADEMY. Disponível em <<http://datascienceacademy.com.br/blog/o-que-e-visao-computacional/>> acessado em 30 de novembro de 2018.